



پروژه درس یادگیری ماشین

پروژه شماره ۴: پیش‌بینی فروش آتی فروشگاه‌های زنجیره‌ای Rossman

نگارش

محمدامین رضائی

محمد مهدی رنجبر

سید جلال‌الدین طباطبایی

استاد درس

دکتر شریفی زارچی

اسفند ۱۴۰۴

دانشگاه صنعتی شریف، دانشکده مهندسی کامپیوتر

به یاد:

تمام جاویدنام‌هایی که در راه آزادی جانشان را فدای میهن کردند.

چکیده

این پروژه بر پایه داده‌های فروش روزانه بیش از ۱۱۰۰ شعبه فروشگاه‌های زنجیره‌ای Rossmann و شامل بیش از یک میلیون رکورد طراحی شده است. هدف آن، توسعه مدلی مبتنی بر یادگیری ماشین برای پیش‌بینی دقیق فروش هر فروشگاه و شناسایی عوامل اثرگذار بر عملکرد فروش است. حجم و تنوع بالای داده‌ها، ضمن فراهم کردن بستر مناسب برای تحلیل‌های پیشرفته، چالش‌هایی در زمینه پردازش و مدل‌سازی ایجاد می‌کند که در این پژوهش به صورت نظام‌مند به آن‌ها پرداخته شده است.

فهرست مطالب

فاز ۱: Data Visualization – تحلیل اکتشافی و شناخت داده‌ها	۸
۱-۱: تحلیل روند فروش در طول زمان	۸
۱-۲: تحلیل روند فروش در طول زمان	۹
۱-۳: تحلیل همبستگی بین متغیرها	۱۱
۱-۴: مقایسه عملکرد فروش براساس نوع فروشگاه	۱۲
فاز ۲: Feature Engineering – مهندسی ویژگی و آماده‌سازی داده	۱۳
۲-۱: بارگذاری، ادغام و فیلتر داده‌ها	۱۳
۲-۲: ایجاد ویژگی‌های زمانی	۱۴
۲-۳: ایجاد ویژگی‌های تأخیری و آمارهای متحرک (Lag & Rolling Features)	۱۴
۲-۴: افزودن مؤلفه‌های فوریه برای مدل‌سازی فصلی بودن (Fourier Terms)	۱۵
۲-۵: پیش‌پردازش نهایی داده‌ها (Encoding, Imputation & Scaling)	۱۵
۲-۶: تفکیک زمانی داده‌ها (Time-Series Split)	۱۶
فاز ۳: Learn & Estimate – آموزش و ارزیابی مدل‌ها	۱۷
۳-۱: آغاز مدل‌سازی و تعریف معیار ارزیابی	۱۷
۳-۲: آموزش مدل پایه (Baseline – Linear Regression)	۱۸
۳-۳: آموزش مدل پیشرفته (XGBoost)	۱۸
۳-۴: تحلیل اهمیت ویژگی‌ها با استفاده از SHAP	۱۹
۳-۵: تحلیل خطا و بررسی باقی‌مانده‌ها (Residual Analysis)	۲۱
فاز ۴: Uncertainty and Sales Classification – تحلیل عدم قطعیت و طبقه‌بندی فروش	۲۳
۴-۱: تخمین عدم قطعیت با Quantile Regression	۲۳
۴-۲: پیش‌بینی چندگامی (۷ روز آینده) به روش بازگشتی	۲۴
۴-۳: طبقه‌بندی فروش به سه سطح کم، متوسط و زیاد	۲۵

فاز ۵: Deep – قسمت عمیق پروژه	۲۷
۵-۱: مهندسی ویژگی‌های زمانی و پاک‌سازی روزهای تعطیل	۲۷
۵-۲: پاک‌سازی نهایی، کدگذاری و تفکیک زمانی داده‌ها	۲۸
۵-۳: ساخت دیتاست توالی برای پیش‌بینی چندگامی و آماده‌سازی DataLoader ها	۲۹
۵-۴: تعریف مدل LSTM برای پیش‌بینی چندگامی (Multi-step) و تنظیم تابع خطا	۳۰
۵-۵: تعریف مدل LSTM برای پیش‌بینی چندگامی (Multi-step) و تنظیم تابع خطا	۳۲
۵-۶: ارزیابی مدل LSTM روی اعتبارسنجی (مقیاس واقعی فروش)	۳۲

مقدمه

پروژه حاضر با تمرکز بر داده‌های فروش فروشگاه‌های زنجیره‌ای Rossmann طراحی شده است. این داده‌ها که از رقابت پیش‌بینی فروش این شرکت استخراج شده‌اند، شامل بیش از یک میلیون رکورد فروش روزانه برای بیش از ۱۱۰۰ فروشگاه هستند. چنین حجم و تنوعی از داده، فرصت ارزشمندی برای تحلیل‌های پیشرفته فراهم می‌کند و در عین حال، چالش‌های متعددی در زمینه پردازش، مهندسی ویژگی، مدل‌سازی و ارزیابی ایجاد می‌نماید. هدف اصلی این پروژه، توسعه یک مدل یادگیری ماشین است که بتواند فروش روزانه هر فروشگاه را با دقت بالا پیش‌بینی کرده و در کنار آن، تحلیل دقیقی از عوامل مؤثر بر عملکرد فروش ارائه دهد.

داده‌های مورد استفاده در این پروژه ترکیبی از متغیرهای عددی، طبقه‌ای و زمانی هستند. علاوه بر ستون هدف (Sales)، اطلاعاتی مانند نوع فروشگاه، فاصله از رقبای، نوع و مدت زمان برگزاری پروموشن‌ها، تعطیلات رسمی (StateHoliday)، تعطیلات مدارس (SchoolHoliday)، و ویژگی‌های تقویمی (روز هفته، ماه، فصل و ...) در اختیار قرار دارند. همچنین فایل جانبی store.csv شامل مشخصات ساختاری هر فروشگاه است که امکان تحلیل عمیق‌تر و ترکیب داده‌های سطح فروشگاه با داده‌های زمانی را فراهم می‌کند. این تنوع ویژگی‌ها، بستر مناسبی برای استخراج الگوهای رفتاری فروش در بازه‌های زمانی مختلف و شرایط متفاوت محیطی ایجاد می‌کند.

رویکرد این پروژه به‌صورت مرحله‌ای و ساختارمند طراحی شده است. در گام نخست، تحلیل اکتشافی داده‌ها (Data Visualization) با هدف درک الگوهای اولیه، روندهای زمانی، اثر تعطیلات و پروموشن‌ها و مقایسه عملکرد فروشگاه‌های مختلف انجام می‌شود. این مرحله نقش اساسی در شناخت رفتار داده‌ها، شناسایی ناهنجاری‌ها و کشف روابط پنهان میان متغیرها ایفا می‌کند. بررسی همبستگی متغیرها و تحلیل روند فروش در طول زمان، دیدی روشن از ساختار مسئله و پیچیدگی‌های آن ارائه می‌دهد. در مرحله بعد، مهندسی ویژگی و آماده‌سازی داده‌ها (Feature Engineering) به‌عنوان یکی از حیاتی‌ترین بخش‌های پروژه انجام می‌شود. در مسائل پیش‌بینی سری‌های زمانی، کیفیت ویژگی‌های استخراج‌شده تأثیر مستقیمی بر عملکرد مدل دارد. در این پروژه، با ترکیب جدول فروش با اطلاعات فروشگاه‌ها بر اساس Store ID، ویژگی‌های زمانی جدید (مانند روز هفته، ماه، فصل)، ویژگی‌های تأخیری (lag features)، میانگین‌های متحرک، آمارهای تجمعی و حتی مؤلفه‌های دوره‌ای مانند Fourier terms استخراج می‌شوند. همچنین مدیریت داده‌های گم‌شده، نرمال‌سازی، و تفکیک داده‌ها به مجموعه‌های آموزش، اعتبارسنجی و آزمون با حفظ ترتیب زمانی انجام می‌گیرد تا از نشت اطلاعات جلوگیری شود.

پس از آماده‌سازی داده‌ها، مرحله آموزش و ارزیابی مدل‌ها (Learn & Estimate) آغاز می‌شود. در این فاز، ابتدا یک مدل پایه (Baseline) ساده برای ایجاد معیار مقایسه پیاده‌سازی می‌شود و سپس مدل‌های پیشرفته‌تری

مانند XGBoost و LightGBM با تنظیم ابرپارامترها آموزش داده می‌شوند. استفاده از اعتبارسنجی زمانی مبتنی بر فروشگاه (store-aware CV) و گزارش معیارهایی مانند Root Mean Squared Error (RMSE) امکان ارزیابی منصفانه عملکرد مدل را فراهم می‌سازد. علاوه بر این، تحلیل اهمیت ویژگی‌ها با استفاده از SHAP انجام می‌شود تا نقش هر متغیر در پیش‌بینی فروش به صورت شفاف تفسیر گردد. این بخش به مدیران کمک می‌کند تا درک بهتری از عوامل کلیدی تأثیرگذار بر فروش داشته باشند.

در ادامه، پروژه وارد فاز تحلیل عدم قطعیت و طبقه‌بندی فروش می‌شود. در این بخش، علاوه بر پیش‌بینی نقطه‌ای فروش، تلاش می‌شود میزان عدم قطعیت پیش‌بینی‌ها با روش‌هایی مانند quantile regression و estimation ensemble برآورد شود. همچنین فروش به کلاس‌های مختلف (کم، متوسط، زیاد) تقسیم شده و یک مدل طبقه‌بندی چندکلاسه با معیارهایی مانند ROC-AUC و F1 Score آموزش داده می‌شود. این رویکرد، دیدی تکمیلی از وضعیت فروش ارائه داده و به تصمیم‌گیری در شرایط عدم اطمینان کمک می‌کند. در نهایت، در فاز عمیق پروژه (Deep Section)، مدل‌های یادگیری عمیق مانند LSTM و TCN برای پیش‌بینی چندگامی (multi-step forecasting) و تخمین عدم قطعیت مورد استفاده قرار می‌گیرند. بهینه‌سازی ابرپارامترها با ابزارهایی مانند Optuna یا Ray Tune انجام شده و نتایج با مدل‌های کلاسیک مقایسه می‌شوند. این بخش نشان‌دهنده ظرفیت روش‌های پیشرفته در استخراج الگوهای پیچیده زمانی و بهبود عملکرد پیش‌بینی است.


فاز ۱: Data Visualization – تحلیل اکتشافی و شناخت داده‌ها

در این مرحله، ابتدا داده‌های اصلی پروژه شامل فایل `train.csv` (اطلاعات فروش روزانه فروشگاه‌ها) و فایل `store.csv` (ویژگی‌های ساختاری هر فروشگاه) بارگذاری شدند. ستون تاریخ به صورت مستقیم به فرمت زمانی (`datetime`) تبدیل شد تا امکان انجام تحلیل‌های سری زمانی و استخراج ویژگی‌های تقویمی فراهم گردد. پس از بارگذاری، دو مجموعه داده بر اساس شناسه فروشگاه (`Store`) با یکدیگر ادغام شدند تا یک دیتافریم جامع شامل اطلاعات فروش و مشخصات فروشگاه‌ها ایجاد شود. نتیجه این ادغام، دیتاستی با ابعاد ۱۰۰۱۵۹۹ سطر و ۲۳ ستون است.

به منظور تقویت قدرت تحلیلی داده‌ها، چندین ویژگی زمانی از ستون `Date` استخراج شد که شامل سال، ماه، روز و شماره هفته در سال است. این ویژگی‌ها امکان بررسی روندهای فصلی، چرخه‌های هفتگی و تغییرات سالانه فروش را فراهم می‌کنند. همچنین ستون `StateHoliday` که دارای مقادیر عددی و متنی بود، به نوع رشته‌ای تبدیل شد و مقدار «۰» به «Regular_Day» تغییر یافت تا تحلیل روزهای تعطیل و غیرتعطیل به صورت شفاف‌تری انجام شود. برای انجام تحلیل اکتشافی دقیق‌تر، تنها رکوردهای مربوط به روزهایی که فروشگاه باز بوده (`Open = 1`) مقدار فروش آن‌ها بزرگ‌تر از صفر بوده است انتخاب شدند. این فیلتر باعث حذف روزهای تعطیلی فروشگاه و داده‌های غیرموثر در تحلیل روند واقعی فروش گردید.

۱-۱: تحلیل روند فروش در طول زمان

به منظور بررسی الگوهای زمانی و تشخیص رفتار فصلی فروش، روند فروش چهار فروشگاه منتخب (۱، ۸۵، ۲۵۹ و ۵۱۲) در بازه زمانی ۲۰۱۳ تا ۲۰۱۵ مورد تحلیل قرار گرفت. برای کاهش نویزهای روزانه و نمایش روندهای کلی‌تر، داده‌های فروش به صورت میانگین هفتگی (`Weekly Average`) بازنمونه‌گیری (`Resample`) شدند.



- وجود روند افزایشی ملایم در برخی فروشگاه‌ها
فروشگاه‌هایی مانند Store 259 و Store 512 روند کلی افزایشی در طول زمان نشان می‌دهند که می‌تواند ناشی از رشد بازار، افزایش تقاضا یا بهبود عملکرد عملیاتی باشد.
 - تفاوت سطح فروش بین فروشگاه‌ها
اختلاف قابل توجهی در سطح میانگین فروش هفتگی بین فروشگاه‌ها مشاهده می‌شود. به‌طور مثال، Store 259 به‌طور پیوسته بالاترین سطح فروش را دارد، در حالی که Store 1 کمترین سطح فروش را در میان فروشگاه‌های منتخب نشان می‌دهد. این موضوع اهمیت در نظر گرفتن ویژگی‌های اختصاصی هر فروشگاه در مدل‌سازی را نشان می‌دهد.
 - وجود نوسانات دوره‌ای (Seasonality)
الگوهای تکرارشونده در طول سال، به‌ویژه افزایش فروش در برخی بازه‌های زمانی خاص، نشان‌دهنده وجود مؤلفه فصلی در داده‌ها است. این موضوع اهمیت استخراج ویژگی‌های زمانی مانند ماه، هفته سال و تعطیلات را در مراحل بعدی پروژه توجیه می‌کند.
 - افزایش واریانس در برخی دوره‌ها
در برخی بازه‌های زمانی (به‌ویژه در سال ۲۰۱۵)، دامنه نوسانات افزایش یافته است که می‌تواند ناشی از کمپین‌های تبلیغاتی، تغییرات تقاضا یا شرایط اقتصادی باشد.
- به‌طور کلی، نتایج این بخش نشان می‌دهد که داده‌های فروش دارای ساختار سری زمانی، روند (Trend) و مؤلفه‌های فصلی (Seasonality) هستند. بنابراین، در مراحل بعدی مدل‌سازی، استفاده از ویژگی‌های زمانی، lag features و روش‌های مناسب سری زمانی کاملاً ضروری خواهد بود.

۱-۲: تحلیل روند فروش در طول زمان

به‌منظور بررسی اثر متغیرهای کلیدی بر میزان فروش، سه عامل مهم شامل Promo، StateHoliday و SchoolHoliday مورد تحلیل قرار گرفتند. نتایج در قالب نمودارهای مقایسه‌ای و توزیعی نمایش داده شده‌اند.



- **تأثیر Promo بر فروش**

بر اساس نمودار مقایسه‌ای، میانگین فروش در روزهایی که پروموشن فعال بوده ($Promo=1$) به‌طور قابل توجهی بالاتر از روزهای عادی ($Promo=0$) است. اختلاف محسوس میان دو ستون نشان می‌دهد که اجرای کمپین‌های تبلیغاتی و تخفیف‌ها تأثیر مستقیم و معناداری بر افزایش فروش داشته است. این نتیجه بیانگر آن است که متغیر **Promo** یکی از مهم‌ترین ویژگی‌های پیش‌بینی فروش خواهد بود و انتظار می‌رود در مدل‌های یادگیری ماشین دارای اهمیت بالایی باشد.

- **تأثیر تعطیلات رسمی (StateHoliday)**


نمودار جعبه‌ای (Boxplot) توزیع فروش را در انواع مختلف تعطیلات رسمی نشان می‌دهد. نتایج نشان می‌دهد که سطح فروش و پراکندگی آن در انواع مختلف تعطیلات متفاوت است. در برخی تعطیلات (به‌ویژه تعطیلات بزرگ)، نوسانات فروش افزایش یافته و مقادیر پرت بیشتری مشاهده می‌شود. این موضوع نشان‌دهنده رفتار متفاوت مشتریان در دوره‌های خاص سال است. وجود توزیع‌های متفاوت و افزایش واریانس در برخی تعطیلات، اهمیت مدل‌سازی اثر تعطیلات را در پیش‌بینی فروش تقویت می‌کند.

- **تأثیر تعطیلات مدارس (SchoolHoliday)**

مقایسه میانگین فروش در روزهای تعطیلی مدارس نشان می‌دهد که فروش در این بازه‌ها اندکی افزایش یافته است. این موضوع می‌تواند ناشی از افزایش حضور خانواده‌ها در فروشگاه‌ها در زمان تعطیلی مدارس باشد. اگرچه اختلاف میانگین فروش در این متغیر به اندازه **Promo** چشمگیر نیست، اما همچنان نشان می‌دهد که **SchoolHoliday** یک متغیر تأثیرگذار در رفتار فروش است و باید در مدل لحاظ شود.

۱-۳: تحلیل همبستگی بین متغیرها

به منظور بررسی روابط خطی میان متغیرهای عددی و شناسایی عوامل اثرگذار بر فروش، ماتریس همبستگی پیرسون بین ویژگی‌های منتخب محاسبه و به صورت نقشه حرارتی (Heatmap) نمایش داده شد.




نتایج نشان می‌دهد که تعداد مشتریان قوی‌ترین همبستگی مثبت را با فروش (0.90) دارد که بیانگر نقش مستقیم حضور مشتریان در افزایش درآمد است. همچنین متغیرهای Open (0.68) و Promo (0.45) دارای همبستگی مثبت قابل توجه با فروش هستند که تأثیر باز بودن فروشگاه و اجرای پروموشن‌ها را تأیید می‌کند. در مقابل، DayOfWeek دارای همبستگی منفی متوسط (-0.46) است که وجود الگوی هفتگی در فروش را نشان می‌دهد. سایر متغیرها مانند CompetitionDistance و Year همبستگی خطی قابل توجهی با فروش

نشان نمی‌دهند. به‌طور کلی، نتایج این بخش اهمیت متغیرهای مشتریان، پروموشن و الگوهای زمانی را در مدل‌سازی فروش تأیید می‌کن.

۱-۴: مقایسه عملکرد فروش بر اساس نوع فروشگاه

به‌منظور بررسی تفاوت عملکرد فروشگاه‌ها، میانگین فروش بر اساس نوع فروشگاه (a, b, c, d) محاسبه و مقایسه شد.



نتایج نشان می‌دهد که فروشگاه‌های نوع b با میانگین فروش حدود 10228 بالاترین عملکرد را دارند و فاصله قابل توجهی با سایر انواع فروشگاه‌ها نشان می‌دهند. در مقابل، فروشگاه‌های انواع a, c و d میانگین فروشی در بازه تقریباً ۶۸۰۰ تا ۷۰۰۰ دارند و اختلاف آن‌ها نسبتاً کم است. این تفاوت بیانگر آن است که نوع فروشگاه یکی از عوامل ساختاری اثرگذار بر سطح فروش بوده و باید در فرآیند مدل‌سازی به‌عنوان یک ویژگی مهم در نظر گرفته شود.

فاز ۲: Feature Engineering – مهندسی ویژگی و آماده‌سازی داده

پس از انجام تحلیل اکتشافی داده‌ها و شناسایی الگوهای زمانی و اثر متغیرهای کلیدی بر فروش، در این مرحله تمرکز پروژه بر غنی‌سازی داده‌ها و آماده‌سازی آن‌ها برای مدل‌سازی قرار گرفت. در مسائل پیش‌بینی سری زمانی، کیفیت و طراحی ویژگی‌ها نقش تعیین‌کننده‌ای در عملکرد مدل‌های یادگیری ماشین دارد؛ از این رو، مهندسی ویژگی به‌عنوان یکی از حیاتی‌ترین مراحل پروژه در نظر گرفته شد. در این فاز، ابتدا جداول فروش و اطلاعات فروشگاه‌ها بر اساس شناسه Store ID ترکیب شدند تا یک دیتاست جامع شامل ویژگی‌های زمانی و ساختاری ایجاد شود. سپس مجموعه‌ای از ویژگی‌های زمانی جدید شامل روز هفته، ماه، فصل و سایر شاخص‌های تقویمی استخراج گردید تا الگوهای فصلی و چرخه‌ای فروش بهتر مدل‌سازی شوند. علاوه بر ویژگی‌های تقویمی، ویژگی‌های وابسته به گذشته (Lag Features) و آمارهای متحرک نظیر میانگین و انحراف معیار فروش در بازه‌های زمانی مختلف ایجاد شدند. این ویژگی‌ها به مدل امکان می‌دهند وابستگی‌های زمانی و حافظه کوتاه‌مدت فروش را درک کند. همچنین برای مدل‌سازی مؤلفه‌های دوره‌ای، از ویژگی‌های تناوبی نظیر Fourier terms استفاده شد. در ادامه، داده‌های گمشده مدیریت و در صورت نیاز نرمال‌سازی انجام شد تا مقیاس متغیرها برای مدل‌های مختلف مناسب باشد. در نهایت، داده‌ها با حفظ ترتیب زمانی به مجموعه‌های آموزش، اعتبارسنجی و آزمون تقسیم شدند تا از نشت اطلاعات جلوگیری شده و ارزیابی مدل به‌صورت واقع‌گرایانه انجام گیرد.

۲-۱: بارگذاری، ادغام و فیلتر داده‌ها

در ابتدای فرآیند مهندسی ویژگی، داده‌های فروش (train.csv) و اطلاعات فروشگاه‌ها (store.csv) مجدداً بارگذاری شدند. سپس دو جدول بر اساس شناسه فروشگاه (Store) با یکدیگر ادغام گردیدند تا یک دیتاست یکپارچه شامل اطلاعات فروش روزانه و ویژگی‌های ساختاری فروشگاه‌ها ایجاد شود. به‌منظور افزایش دقت مدل‌سازی و حذف داده‌های غیرمؤثر، تنها رکوردهای مربوط به روزهایی که فروشگاه باز بوده ($Open = 1$) و مقدار فروش آن‌ها بزرگ‌تر از صفر بوده است نگه داشته شدند. این فیلتر باعث حذف روزهای تعطیلی و داده‌های بدون فروش شده و تمرکز تحلیل را بر رفتار واقعی فروش حفظ می‌کند. در نهایت، داده‌ها بر اساس شناسه فروشگاه و تاریخ مرتب‌سازی شدند. این مرحله برای ایجاد صحیح ویژگی‌های تأخیری (Lag Features) و محاسبات وابسته به زمان کاملاً ضروری است، زیرا ترتیب زمانی داده‌ها باید حفظ شود تا از بروز خطا و نشت اطلاعات جلوگیری گردد.

۲-۲: ایجاد ویژگی‌های زمانی

با توجه به ماهیت سری زمانی مسئله پیش‌بینی فروش، استخراج ویژگی‌های زمانی یکی از مهم‌ترین مراحل مهندسی ویژگی محسوب می‌شود. در این بخش، مجموعه‌ای از متغیرهای تقویمی از ستون تاریخ (Date) استخراج گردید که شامل سال، ماه، روز، روز هفته و شماره هفته سال است. این ویژگی‌ها امکان مدل‌سازی الگوهای فصلی، چرخه‌های هفتگی و تغییرات دوره‌ای فروش را فراهم می‌کنند. همچنین متغیر IsWeekend ایجاد شد تا روزهای پایانی هفته (شنبه و یکشنبه) از سایر روزها تفکیک شوند. این ویژگی می‌تواند رفتار متفاوت مشتریان در آخر هفته را برای مدل آشکار کند. علاوه بر ویژگی‌های تقویمی، به‌منظور در نظر گرفتن اثر رقبا، مدت زمان فعالیت رقبا نیز محاسبه شد. ابتدا تاریخ شروع فعالیت رقبا بر اساس اطلاعات سال و ماه ثبت‌شده ساخته شد و سپس تعداد روزهای سپری‌شده از زمان شروع فعالیت رقبا تا هر تاریخ محاسبه گردید (CompetitionDaysOpen). این متغیر نشان می‌دهد که حضور طولانی‌تر رقبا ممکن است چگونه بر فروش فروشگاه اثر بگذارد. در مجموع، این مرحله باعث غنی‌تر شدن داده‌ها از نظر اطلاعات زمانی و محیط رقابتی شده و بستر مناسبی برای مدل‌سازی دقیق‌تر فراهم می‌کند.

۲-۳: ایجاد ویژگی‌های تأخیری و آمارهای متحرک (Lag & Rolling Features)

به‌منظور مدل‌سازی وابستگی زمانی فروش و در نظر گرفتن حافظه کوتاه‌مدت داده‌ها، مجموعه‌ای از ویژگی‌های تأخیری (Lag Features) و آمارهای متحرک ایجاد شد. از آنجا که فروش هر روز به میزان فروش روزهای قبل وابسته است، این ویژگی‌ها نقش مهمی در افزایش قدرت پیش‌بینی مدل دارند. در این بخش، برای هر فروشگاه به‌صورت مجزا و با حفظ ترتیب زمانی، فروش روزهای گذشته محاسبه شد. به‌طور مشخص، مقادیر فروش با تأخیرهای ۱ روزه، ۲ روزه و ۷ روزه (Sales_Lag1, Sales_Lag2, Sales_Lag7) ایجاد گردید. استفاده از تأخیر ۷ روزه به مدل کمک می‌کند الگوهای هفتگی تکرارشونده را درک کند. علاوه بر آن، آمارهای متحرک شامل میانگین متحرک ۷ روزه (Sales_RollMean7) و انحراف معیار متحرک ۷ روزه (Sales_RollStd7) محاسبه شدند. این ویژگی‌ها اطلاعاتی درباره سطح متوسط فروش اخیر و میزان نوسانات آن در اختیار مدل قرار می‌دهند. نکته مهم در این مرحله، اعمال عملگر shift قبل از محاسبه میانگین و انحراف معیار است تا از نشت اطلاعات (Data Leakage) جلوگیری شود؛ بدین معنا که در پیش‌بینی هر روز، تنها از اطلاعات گذشته استفاده گردد. در نهایت، رکوردهایی که به دلیل ایجاد تأخیرها دارای مقادیر گم‌شده بودند حذف شدند تا داده‌ها برای ورود به مرحله مدل‌سازی آماده شوند.

۲-۴: افزودن مؤلفه‌های فوریه برای مدل‌سازی فصلی بودن (Fourier Terms)

به منظور مدل‌سازی دقیق‌تر الگوهای تناوبی و فصلی در داده‌های فروش، از تبدیلات فوریه استفاده شد. در مسائل سری زمانی، بسیاری از الگوهای فصلی به صورت دوره‌ای و غیرخطی ظاهر می‌شوند و استفاده از توابع سینوسی و کسینوسی امکان نمایش پیوسته این چرخه‌ها را فراهم می‌کند.

در این بخش، دو نوع تناوب اصلی در داده‌ها مدل‌سازی شد:

• تناوب هفتگی (دوره ۷ روزه):

با استفاده از توابع سینوس و کسینوس بر اساس روز هفته، مؤلفه‌های `day_sin` و `day_cos` ایجاد شدند. این ویژگی‌ها به مدل کمک می‌کنند الگوی تکرارشونده فروش در طول هفته را بدون ایجاد گسستگی عددی (مانند فاصله بین روز ۶ و ۰) درک کند.

• تناوب سالانه (دوره ۳۶۵ روزه)

با استفاده از شماره روز در سال، ویژگی‌های `year_sin` و `year_cos` ساخته شدند تا چرخه‌های سالانه و تغییرات فصلی بلندمدت در فروش مدل‌سازی شوند.

استفاده از ویژگی‌های فوریه به مدل اجازه می‌دهد رفتارهای فصلی را به صورت نرم و پیوسته یاد بگیرد و نسبت به استفاده صرف از متغیرهای گسسته زمانی، عملکرد بهتری در پیش‌بینی ارائه دهد.

۲-۵: پیش‌پردازش نهایی داده‌ها (Encoding, Imputation & Scaling)

در این مرحله، داده‌ها برای ورود به مدل‌های یادگیری ماشین آماده‌سازی نهایی شدند. ابتدا مقادیر گمشده در متغیر `CompetitionDistance` با استفاده از مقدار میانه (`Median`) جایگزین شدند تا اثر داده‌های پرت کاهش یابد. سپس سایر مقادیر گمشده احتمالی با مقدار صفر پر شدند تا ساختار داده‌ها کامل گردد.

در ادامه، متغیرهای طبقه‌ای شامل `StateHoliday`، `StoreType` و `Assortment` با استفاده از روش `Label Encoding` به مقادیر عددی تبدیل شدند. این تبدیل برای استفاده از این متغیرها در مدل‌های یادگیری ماشین ضروری است. در نهایت، برخی از ویژگی‌های عددی مهم شامل `CompetitionDistance`، `CompetitionDaysOpen`، `Sales_RollMean7` و `Sales_RollStd7` با استفاده از روش `MinMax Scaling` به بازه `[0,1]` نرمال‌سازی شدند. این کار باعث هم‌مقیاس شدن متغیرها و بهبود پایداری و عملکرد مدل، به‌ویژه در الگوریتم‌های حساس به مقیاس داده‌ها، می‌شود. با تکمیل این مرحله، داده‌ها از نظر ساختاری و عددی آماده ورود به فاز مدل‌سازی شدند.

۲-۶: تفکیک زمانی داده‌ها (Time-Series Split)

بر این اساس، داده‌ها به سه بخش تقسیم شدند:

- مجموعه آموزش (Training Set): شامل ۷۴۵,۳۲۲
- مجموعه اعتبارسنجی (Validation Set): شامل ۳۶,۳۷۶
- مجموعه آزمون (Test Set): شامل ۴۱,۴۱۵

برای ارزیابی واقع‌گرایانه مدل، شش هفته پایانی به‌عنوان مجموعه آزمون و شش هفته قبل از آن به‌عنوان مجموعه اعتبارسنجی در نظر گرفته شد. در ادامه، ستون هدف (Sales) از سایر ویژگی‌ها جدا شد و متغیرهایی که ممکن بود موجب نشت اطلاعات شوند مانند Date ، Customer و Open از مجموعه ویژگی‌ها حذف گردیدند. در نهایت، ۲۸ ویژگی مهندسی‌شده به‌عنوان ورودی نهایی مدل انتخاب شدند که شامل ویژگی‌های زمانی، تأخیری، آماری، رقابتی و مؤلفه‌های فوریه هستند.

فاز ۳: Learn & Estimate – آموزش و ارزیابی مدل‌ها

پس از تکمیل فرآیند مهندسی ویژگی و آماده‌سازی داده‌ها، در این مرحله مدل‌های پیش‌بینی فروش توسعه و ارزیابی شدند. هدف اصلی این فاز، ساخت مدلی با دقت بالا برای پیش‌بینی فروش روزانه هر فروشگاه و مقایسه عملکرد الگوریتم‌های مختلف یادگیری ماشین بود. در ابتدا یک مدل پایه (Baseline) به‌منظور ایجاد معیار مقایسه پیاده‌سازی شد. سپس مدل‌های پیشرفته‌تر از جمله الگوریتم‌های مبتنی بر گرادیان بوستینگ مانند XGBoost و LightGBM آموزش داده شدند. برای جلوگیری از نشت اطلاعات و ارزیابی واقع‌گرایانه، از تقسیم زمانی داده‌ها و اعتبارسنجی مناسب سری زمانی استفاده شد. عملکرد مدل‌ها با استفاده از معیار **Root Mean Squared Error (RMSE)** ارزیابی گردید و علاوه بر آن، تحلیل اهمیت ویژگی‌ها و بررسی خطاها به‌منظور درک بهتر رفتار مدل انجام شد.

در ابتدای فاز مدل‌سازی، مراحل اصلی پیش‌پردازش و مهندسی ویژگی فاز قبل به‌صورت یکپارچه مجدداً اجرا شد تا داده‌ها به شکل نهایی و قابل استفاده برای آموزش مدل‌ها آماده شوند. این مراحل شامل ادغام داده‌های فروش و اطلاعات فروشگاه‌ها، استخراج ویژگی‌های زمانی، ایجاد ویژگی‌های تأخیری (Lag) و میانگین متحرک، مدیریت داده‌های گمشده و کدگذاری متغیرهای طبقه‌ای بود. پس از تکمیل پیش‌پردازش، داده‌ها به‌صورت زمانی و بدون اختلاط آینده با گذشته تقسیم شدند؛ به‌طوری‌که شش هفته پایانی به‌عنوان مجموعه آزمون و شش هفته قبل از آن به‌عنوان مجموعه اعتبارسنجی در نظر گرفته شد. این رویکرد ارزیابی واقع‌گرایانه‌تری از عملکرد مدل فراهم می‌کند.

در نهایت، ماتریس ویژگی‌ها و متغیر هدف استخراج شد. ابعاد نهایی داده‌ها به شرح زیر است:

- مجموعه آموزش $(745,322 \times 21)$
- مجموعه آزمون $(41,415 \times 21)$

که نشان می‌دهد مدل با ۲۱ ویژگی ورودی آموزش داده خواهد شد.

با تکمیل این مرحله، داده‌ها آماده ورود به بخش آموزش مدل پایه و مدل‌های پیشرفته شدند.

۳-۱: آغاز مدل‌سازی و تعریف معیار ارزیابی

در این بخش، فرآیند آموزش و ارزیابی مدل‌های پیش‌بینی فروش آغاز شد. برای مقایسه دقیق عملکرد مدل‌ها، یک تابع اختصاصی جهت محاسبه معیار **Root Mean Squared Error (RMSE)** تعریف گردید. معیار RMSE به‌عنوان معیار اصلی ارزیابی انتخاب شد، زیرا این شاخص میزان انحراف پیش‌بینی‌ها از مقادیر واقعی را

اندازه‌گیری کرده و به خطاهای بزرگ وزن بیشتری می‌دهد. با توجه به ماهیت مسئله پیش‌بینی فروش و اهمیت کاهش خطاهای بزرگ در مقادیر بالا، استفاده از RMSE انتخاب مناسبی محسوب می‌شود.

۲-۳: آموزش مدل پایه (Baseline – Linear Regression)

ابتدا یک مدل پایه مبتنی بر رگرسیون خطی (Linear Regression) آموزش داده شد. این مدل به‌عنوان ساده‌ترین مدل خطی، روابط مستقیم بین ویژگی‌ها و فروش را بدون در نظر گرفتن برهم‌کنش‌های پیچیده یا غیرخطی مدل‌سازی می‌کند. پس از آموزش مدل بر روی مجموعه آموزش، پیش‌بینی‌ها بر روی مجموعه آزمون انجام شد و عملکرد مدل با استفاده از معیار RMSE ارزیابی گردید.

نتیجه به‌دست‌آمده:

$$\text{Baseline RMSE} = 1534.5094$$

این مقدار نشان می‌دهد که به‌طور متوسط، پیش‌بینی‌های مدل حدود ۱۵۳۴ واحد فروش با مقدار واقعی اختلاف دارند. با توجه به دامنه فروش در داده‌ها، این مقدار خطا مبنای مقایسه‌ای مناسبی برای ارزیابی مدل‌های پیشرفته‌تر مانند XGBoost فراهم می‌کند. از آنجا که رگرسیون خطی تنها قادر به مدل‌سازی روابط خطی است، انتظار می‌رود مدل‌های غیرخطی مبتنی بر گرادیان بوستینگ عملکرد بهتری ارائه دهند.

۳-۳: آموزش مدل پیشرفته (XGBoost)

پس از ارزیابی مدل پایه، یک مدل پیشرفته مبتنی بر الگوریتم XGBoost Regressor آموزش داده شد. این الگوریتم از تکنیک گرادیان بوستینگ برای ساخت مجموعه‌ای از درخت‌های تصمیم استفاده می‌کند و قادر است روابط غیرخطی و برهم‌کنش‌های پیچیده بین ویژگی‌ها را مدل‌سازی کند.

برای بهبود عملکرد مدل و جلوگیری از بیش‌برازش (Overfitting)، از تکنیک‌های زیر استفاده شد:

- نرخ یادگیری پایین (Learning Rate = 0.05)
- استفاده از ۱۰۰۰ درخت تصمیم
- محدودسازی عمق درخت‌ها (max_depth = 10)
- نمونه‌گیری تصادفی از داده‌ها و ویژگی‌ها (subsample) و (colsample_bytree)

- استفاده از Early Stopping با ۵۰ تکرار بدون بهبود

مدل با استفاده از مجموعه آموزش و اعتبارسنجی به صورت همزمان آموزش داده شد و روند کاهش خطا در طول تکرارها پایش گردید.

نتایج ارزیابی:

XGBoost RMSE = 879.6774


در مقایسه با مدل پایه:

میزان بهبود = ۶۵۴.۸۳۲۰ واحد فروش

این کاهش چشمگیر در مقدار RMSE نشان می‌دهد که مدل XGBoost توانسته ساختار غیرخطی داده‌ها و وابستگی‌های زمانی را به مراتب بهتر از رگرسیون خطی یاد بگیرد. کاهش بیش از ۴۰ درصدی خطا نسبت به مدل پایه بیانگر کارایی بالای الگوریتم‌های مبتنی بر گرادیان بوستینگ در مسائل پیش‌بینی فروش است.

۳-۴: تحلیل اهمیت ویژگی‌ها با استفاده از SHAP

به منظور تفسیرپذیری مدل XGBoost و بررسی میزان تأثیر هر ویژگی بر پیش‌بینی فروش، از روش SHAP (SHapley Additive exPlanations) استفاده شد. این روش با محاسبه سهم هر ویژگی در خروجی مدل، امکان تحلیل دقیق و محلی (برای هر نمونه) و همچنین تحلیل کلی (Global Importance) را فراهم می‌کند.



بر اساس نمودار SHAP ، مهم‌ترین ویژگی‌های مؤثر بر پیش‌بینی فروش به ترتیب عبارت‌اند از:

- Sales_RollMean7
- Sales_Lag1

- **Promo**
- **DayOfWeek**

نکات کلیدی:

Sales_RollMean7 (میانگین متحرک ۷ روزه) بیشترین تأثیر را بر پیش‌بینی مدل دارد. مقادیر بالای این ویژگی (نقاط قرمز) موجب افزایش مقدار پیش‌بینی فروش شده‌اند، که نشان می‌دهد مدل به‌شدت به روند اخیر فروش وابسته است.

Sales_Lag1 (فروش روز قبل) دومین متغیر مهم است و بیانگر وابستگی قوی فروش به روز قبل می‌باشد. این موضوع اهمیت ساختار سری زمانی در داده‌ها را تأیید می‌کند.

Promo اثر مثبت قابل توجهی بر فروش دارد؛ زمانی که پروموشن فعال است، **SHAP** مقدار مثبت‌تری به خروجی مدل اضافه می‌کند که منجر به افزایش پیش‌بینی فروش می‌شود.


DayOfWeek نیز نقش مهمی ایفا می‌کند که نشان‌دهنده وجود الگوی هفتگی در رفتار فروش است.

در مقابل، متغیرهایی مانند **SchoolHoliday**، **Promo2** و **Id** تأثیر بسیار محدودتری بر خروجی مدل داشته‌اند.

۳-۵: تحلیل خطا و بررسی باقی‌مانده‌ها (Residual Analysis)

به‌منظور ارزیابی دقیق‌تر عملکرد مدل **XGBoost**، توزیع خطاها (**Residuals**) مورد بررسی قرار گرفت. خطا به‌صورت اختلاف بین مقدار واقعی و مقدار پیش‌بینی شده تعریف شد:

$$\text{Error} = \text{Actual} - \text{Predicted}$$



نمودار توزیع باقی‌مانده‌ها نشان می‌دهد که اکثر خطاها حول صفر متمرکز هستند که بیانگر عملکرد مناسب مدل در پیش‌بینی مقادیر معمول فروش است. شکل تقریباً زنگوله‌ای توزیع خطا نشان می‌دهد که مدل دارای بایاس سیستماتیک شدید نیست. با این حال، وجود دنباله‌های کشیده در دو سمت نمودار نشان‌دهنده حضور برخی پیش‌بینی‌های با خطای بالا است. این موارد معمولاً مربوط به روزهای خاص با فروش غیرعادی (مانند پروموشن‌های شدید یا رویدادهای خاص) هستند.

پنج نمونه با بیشترین مقدار خطای مطلق استخراج شدند. در این موارد، اختلاف قابل توجهی بین مقدار واقعی و مقدار پیش‌بینی‌شده مشاهده می‌شود (در برخی موارد بیش از ۱۵,۰۰۰ واحد فروش).

این خطاهای بزرگ احتمالاً ناشی از:

- رخ داده‌های غیرمعمول فروش
- رفتارهای نادر مشتریان
- یا شرایط خاصی که در داده‌ها به‌طور کامل مدل‌سازی نشده‌اند

می‌باشد.

فاز ۴: Uncertainty and Sales Classification – تحلیل عدم قطعیت و

طبقه بندی فروش

در فازهای پیشین، تمرکز اصلی پروژه بر پیش‌بینی نقطه‌ای (Point Forecast) فروش روزانه هر فروشگاه بود. با این حال، در مسائل واقعی کسب‌وکار، صرفاً دانستن یک مقدار پیش‌بینی‌شده کافی نیست؛ بلکه میزان عدم قطعیت (Uncertainty) و دامنه خطای احتمالی پیش‌بینی نیز اهمیت بالایی دارد. علاوه بر آن، در بسیاری از تصمیمات مدیریتی، دسته‌بندی فروش به سطوح مختلف (کم، متوسط، زیاد) کاربردی‌تر از مقدار دقیق فروش است.

در این فاز، پروژه در سه محور اصلی گسترش یافت:

۱. پیاده‌سازی پیش‌بینی چندگامی (Multi-step Forecasting)
به‌منظور پیش‌بینی فروش در چند روز آینده (مثلاً ۷ روز)، با در نظر گرفتن اثر انتشار خطا در طول زمان.
 ۲. تخمین عدم قطعیت پیش‌بینی‌ها
با استفاده از روش‌هایی مانند Quantile Regression یا رویکردهای Ensemble، دامنه اطمینان برای پیش‌بینی‌ها محاسبه شد تا میزان ریسک تصمیم‌گیری مشخص گردد.
 ۳. طبقه‌بندی فروش به سطوح مختلف
فروش به سه کلاس «کم»، «متوسط» و «زیاد» تقسیم شد و یک مدل طبقه‌بندی چندکلاسه آموزش داده شد. عملکرد مدل با معیارهایی مانند F1-score و ROC-AUC ارزیابی گردید.
- هدف این فاز، افزایش کاربردپذیری مدل در تصمیم‌گیری‌های مدیریتی و ارائه تصویری جامع‌تر از رفتار فروش تحت شرایط مختلف است.

۴-۱ تخمین عدم قطعیت با Quantile Regression

برای برآورد عدم قطعیت، از Quantile Regression با استفاده از مدل GradientBoostingRegressor بهره گرفته شد. در این روش، به‌جای پیش‌بینی یک مقدار واحد، چندک‌های مختلف فروش پیش‌بینی می‌شوند تا بازه‌ای از مقادیر محتمل به‌دست آید. در این پروژه سه مدل مجزا برای چندک‌های ۵٪ (Lower)، ۵۰٪ (Median) و ۹۵٪ (Upper) آموزش داده شد. خروجی این سه مدل یک بازه اطمینان (تقریباً ۹۰٪) در اطراف پیش‌بینی میانه ایجاد می‌کند که برای مدیریت ریسک و تصمیم‌گیری واقعی بسیار کاربردی است.


در نمودار عدم قطعیت، مشاهده می‌شود که مقدار واقعی فروش معمولاً در محدوده بین کران پایین و بالا قرار می‌گیرد و پهنای این بازه نشان‌دهنده سطح عدم قطعیت در روزهای مختلف است؛ به‌طوری‌که در برخی بازه‌ها (روزهای پرتلاطم‌تر) بازه اطمینان پهن‌تر شده و نشان می‌دهد پیش‌بینی در آن روزها دشوارتر است.

۴-۲: پیش‌بینی چندگامی (۷ روز آینده) به روش بازگشتی

در ادامه، پیش‌بینی چندگامی فروش برای ۷ روز آینده به روش Recursive Multi-step Forecasting پیاده‌سازی شد. در این روش، مدل ابتدا فروش روز بعد را پیش‌بینی می‌کند و سپس همان مقدار پیش‌بینی‌شده به‌عنوان ورودی (به‌روزرسانی lag ها) برای پیش‌بینی روزهای بعدی استفاده می‌شود. این رویکرد ساده و قابل پیاده‌سازی است، اما به دلیل استفاده از خروجی‌های پیش‌بینی‌شده به‌جای مقادیر واقعی، مسئله انتشار خطا (Error Propagation) ممکن است رخ دهد.

برای نمایش عملکرد، یک فروشگاه نمونه انتخاب و حلقه بازگشتی ۷ روزه اجرا شد. خروجی پیش‌بینی ۷ روزه برای فروشگاه نمونه به صورت زیر به‌دست آمد:

[6016, 5861, 5750, 5741, 5741, 5741, 5741]




همان‌طور که نمودار نشان می‌دهد، پیش‌بینی‌ها در روزهای ابتدایی کاهش پیدا کرده و سپس به یک مقدار تقریباً پایدار همگرا می‌شوند. این رفتار می‌تواند ناشی از ساختار ویژگی‌های استفاده‌شده (به‌خصوص وابستگی به lag1 و rolling mean) و همچنین ساده‌سازی فرآیند به‌روزرسانی ویژگی‌ها در حلقه بازگشتی باشد.

۳-۴: طبقه‌بندی فروش به سه سطح کم، متوسط و زیاد

در بخش سوم، مسئله به صورت یک مسئله طبقه‌بندی چندکلاسه تعریف شد تا به جای پیش‌بینی مقدار دقیق فروش، سطح فروش پیش‌بینی شود. برای این منظور، فروش به سه کلاس Low / Medium / High بر اساس تقسیم‌بندی چندکی (qcut) تبدیل شد. سپس یک مدل XGBoost Classifier آموزش داده شد و عملکرد آن با معیارهای F1-score و ROC-AUC ارزیابی گردید.

نتایج گزارش طبقه‌بندی نشان می‌دهد:

- کلاس Low: $F1 \approx 0.86$
- کلاس Medium: $F1 \approx 0.85$
- کلاس High: $F1 \approx 0.73$
- $Accuracy \approx 0.81$ کلی
- $Weighted F1 \approx 0.8115$
- $ROC-AUC = 0.9402$



در مجموع، فاز ۴ سه خروجی کلیدی ارائه کرد:

۱. پیش‌بینی فروش همراه با بازه اطمینان با استفاده از Quantile Regression ،
۲. پیاده‌سازی پیش‌بینی چندگامی ۷ روزه و بررسی رفتار انتشار خطا،
۳. تبدیل مسئله به طبقه‌بندی سطح فروش و دستیابی به عملکرد مناسب با $\text{Weighted F1} \approx 0.81$ و $\text{ROC-AUC} \approx 0.94$.

این نتایج نشان می‌دهد علاوه بر پیش‌بینی مقدار فروش، می‌توان با ابزارهای عدم قطعیت و طبقه‌بندی، تحلیل کاربردی‌تری برای تصمیم‌گیری مدیریتی ارائه داد.

فاز ۵: Deep – قسمت عمیق پروژه

در فازهای قبلی، با استفاده از مهندسی ویژگی و مدل‌های کلاسیک یادگیری ماشین مانند XGBoost، پیش‌بینی فروش با دقت مناسب انجام شد و همچنین تحلیل عدم قطعیت و طبقه‌بندی فروش توسعه یافت. با این حال، مدل‌های کلاسیک معمولاً برای استخراج الگوهای پیچیده و بلندمدت سری‌های زمانی به مهندسی ویژگی وابسته‌اند. به همین دلیل، در این فاز از مدل‌های یادگیری عمیق استفاده شد تا وابستگی‌های زمانی پیچیده به صورت مستقیم از داده‌ها یاد گرفته شوند و امکان اجرای پیش‌بینی چندگامی و برآورد عدم قطعیت به شکل دقیق‌تر فراهم گردد. در این فاز، سه محور اصلی دنبال شد:

۱. پیش‌بینی چندگامی (Multi-step Forecasting) با مدل‌های عمیق
با هدف پیش‌بینی فروش چند روز آینده، معماری‌هایی مانند LSTM و TCN به کار گرفته شدند تا وابستگی‌های کوتاه‌مدت و بلندمدت سری زمانی را به صورت موثر مدل‌سازی کنند.
۲. تخمین عدم قطعیت همراه با پیش‌بینی
در کنار پیش‌بینی مقدار فروش، تلاش شد بازه اطمینان پیش‌بینی نیز با استفاده از روش‌های مناسب مدل‌های عمیق (مانند رویکردهای احتمالی یا چندک‌ها) برآورد شود تا خروجی مدل برای تصمیم‌گیری واقعی قابل اتکاتر گردد.
۳. تفسیرپذیری مدل (SHAP/Feature Attribution)
با وجود پیچیدگی مدل‌های عمیق، تحلیل تفسیرپذیری جهت شناخت عوامل اثرگذار بر پیش‌بینی‌ها انجام شد تا مشخص شود مدل چه الگوهایی را مهم‌تر در نظر می‌گیرد و آیا رفتار آن با منطق کسب‌وکار هم‌راستا است.

همچنین برای دستیابی به بهترین عملکرد، تنظیم ابرپارامترها با ابزارهایی مانند Optuna یا Ray Tune انجام گرفت تا پارامترهایی مانند تعداد لایه‌ها، اندازه پنجره زمانی (Lookback)، نرخ یادگیری و اندازه batch بهینه شوند. در نهایت، نتایج مدل‌های عمیق از نظر دقت پیش‌بینی، پایداری در چندگام آینده و کیفیت تخمین عدم قطعیت با مدل‌های کلاسیک مقایسه شد تا مزایا و محدودیت‌های هر رویکرد به صورت شفاف مشخص گردد.

۵-۱: مهندسی ویژگی‌های زمانی و پاک‌سازی روزهای تعطیل

در این مرحله، داده‌ها بر اساس شناسه فروشگاه و تاریخ مرتب‌سازی شدند تا ساختار سری زمانی هر فروشگاه به صورت پیوسته و منظم حفظ شود. سپس روزهایی که فروشگاه بسته بوده است ($Open = 0$) حذف شدند،

زیرا در این روزها معمولاً مقدار فروش صفر است و وجود آن‌ها می‌تواند باعث ایجاد نویز در فرآیند یادگیری مدل‌های پیش‌بینی شود. این فیلتر باعث تمرکز مدل بر رفتار واقعی فروش در روزهای فعال گردید.

پس از این مرحله، مجموعه‌ای از ویژگی‌های زمانی جدید ایجاد شد که شامل سال، ماه، روز، شماره هفته سال، شروع و پایان ماه است. این ویژگی‌ها به مدل کمک می‌کنند الگوهای تقویمی و تغییرات دوره‌ای فروش را بهتر درک کند. علاوه بر آن، برای حفظ پیوستگی چرخه‌های فصلی، از کدگذاری تناوبی (Cyclic Encoding) برای ماه و روز هفته استفاده شد (Month_sin/cos و DOW_sin/cos). این روش باعث می‌شود مدل ارتباط بین مقادیر مرزی (مانند ماه ۱۲ و ۱) را به‌صورت نرم و پیوسته یاد بگیرد. در ادامه، یک ویژگی مرتبط با رقابت ایجاد شد. با استفاده از سال و ماه شروع فعالیت رقبا، مدت زمان فعالیت رقبا به‌صورت تقریبی بر حسب ماه (CompOpenMonths) محاسبه گردید. مقادیر منفی یا نامعتبر به صفر محدود شدند تا از ورود داده‌های ناسازگار جلوگیری شود.

همچنین متغیر PromoInterval به تعداد ماه‌های فعال پروموشن تبدیل شد (PromoIntervalCount) تا به‌جای یک مقدار متنی، یک شاخص عددی قابل استفاده در مدل ایجاد شود.

در نهایت، برای برخی متغیرهای عددی مرتبط با رقابت و پروموشن، مقدارهای گم‌شده با استفاده از میانه جایگزین شدند تا توزیع داده‌ها کمتر تحت تأثیر مقادیر پرت قرار گیرد.

پس از اعمال این مراحل، ابعاد داده‌ها به $(830,972 \times 31)$ رسید که نشان‌دهنده حذف روزهای تعطیل و افزودن ویژگی‌های جدید است. دامنه فروش نیز بین 0 تا ۴۱,۵۵۱ واحد باقی ماند که نشان می‌دهد داده‌ها بدون تحریف مقادیر اصلی برای ورود به مدل‌های عمیق آماده شده‌اند.

۵-۲: پاک‌سازی نهایی، کدگذاری و تفکیک زمانی داده‌ها

در این مرحله، آماده‌سازی نهایی داده‌ها برای آموزش مدل‌های عمیق انجام شد. ابتدا رکوردهایی که مقدار فروش آن‌ها برابر صفر بود حذف شدند، زیرا وجود این مقادیر می‌تواند موجب ناپایداری در فرآیند یادگیری و اختلال در مدل‌سازی توالی‌های زمانی شود. پس از این فیلتر، ابعاد داده‌ها به $(830,918 \times 31)$ کاهش یافت که نشان‌دهنده حذف تعداد محدودی از نمونه‌های غیرمؤثر است.

در ادامه، متغیرهای طبقه‌ای شامل StoreType، Assortment و StateHoliday با استفاده از روش Label Encoding به مقادیر عددی تبدیل شدند تا برای ورود به مدل‌های عصبی قابل استفاده باشند. سپس ستون‌هایی که نقشی در مدل‌سازی نداشتند (مانند Id) حذف شدند.

به منظور جلوگیری از نشت اطلاعات آینده به گذشته، داده‌ها مجدداً بر اساس فروشگاه و تاریخ مرتب‌سازی شدند و تقسیم داده‌ها به صورت زمان محور (Time-based split) انجام گرفت. در این تقسیم‌بندی، حدود ۸۰٪ ابتدایی بازه زمانی به عنوان مجموعه آموزش و ۲۰٪ انتهایی به عنوان مجموعه اعتبارسنجی در نظر گرفته شد. نتایج این تفکیک به شرح زیر است:

Train shape: $(664,801 \times 30)$ •
Validation shape: $(166,117 \times 30)$ •

در نهایت، ۱۷ ویژگی نهایی برای ورود به مدل انتخاب شد که شامل ویژگی‌های زمانی، تناوبی (sin/cos)، رقابتی و مرتبط با پروموشن است. ستون هدف نیز Sales در نظر گرفته شد. این ساختار داده، بستر مناسبی برای ساخت توالی‌های زمانی (Lookback Windows) و آموزش مدل‌های عمیق مانند LSTM و TCN فراهم می‌کند.

۵-۳: ساخت دیتاست توالی برای پیش‌بینی چندگامی و آماده‌سازی Data Loader ها

برای آموزش مدل‌های یادگیری عمیق مانند LSTM و TCN لازم است داده‌ها به شکل توالی‌های زمانی (Sequence) تبدیل شوند. در این پروژه، مسئله به صورت پیش‌بینی چندگامی (Multi-step Forecasting) تعریف شد؛ به این معنا که مدل با مشاهده فروش و ویژگی‌های ۳۰ روز گذشته، فروش ۷ روز آینده را به صورت همزمان پیش‌بینی می‌کند.

در این مرحله، پارامترهای اصلی ساخت توالی به صورت زیر تنظیم شدند:

- طول پنجره ورودی (LOOKBACK) برابر ۳۰ روز
- افق پیش‌بینی (HORIZON) برابر ۷ روز
- اندازه دسته (BATCH_SIZE) برابر ۲۵۶

برای جلوگیری از نشت اطلاعات و بهبود روند یادگیری شبکه عصبی، ویژگی‌ها و متغیر هدف با استفاده از StandardScaler نرمال‌سازی شدند. نکته مهم این است که مقادیر scaler فقط روی داده‌های آموزش (Train) برازش (fit) شد و سپس همان پارامترها برای تبدیل داده‌های اعتبارسنجی (Validation) استفاده گردید. این کار باعث می‌شود توزیع داده‌های آینده وارد فرآیند آموزش نشود و ارزیابی مدل واقع‌گرایانه باقی بماند.

از آنجا که هر فروشگاه یک سری زمانی مستقل دارد، توالی‌ها به صورت store-wise ساخته شدند؛ یعنی برای هر فروشگاه، پس از مرتب‌سازی بر اساس تاریخ، پنجره‌های لغزان ایجاد شد تا خروجی نهایی به شکل زیر باشد:

- X : آرایه سه‌بعدی با ابعاد $[N, 30, 17]$

- y : آرایه دوبعدی با ابعاد $[N, 7]$

نتیجه ساخت توالی‌ها:

- $X_{\text{train}} = (624,661, 30, 17)$ و $y_{\text{train}} = (624,661, 7)$

- $X_{\text{val}} = (125,977, 30, 17)$ و $y_{\text{val}} = (125,977, 7)$

این ابعاد نشان می‌دهد که تعداد بسیار زیادی نمونه آموزشی از داده‌ها استخراج شده است که برای آموزش شبکه‌های عمیق مناسب بوده و امکان یادگیری الگوهای زمانی را تقویت می‌کند.

در ادامه، یک Dataset سفارشی تعریف شد و داده‌ها در قالب DataLoaderهای PyTorch آماده شدند تا آموزش مدل به‌صورت batch-wise انجام شود. بررسی یک batch نمونه نشان داد:

- Batch X: (256, 30, 17)

- Batch y: (256, 7)

که با تعریف مسئله (ورودی ۳۰ روزه و خروجی ۷ روزه) کاملاً سازگار است. همچنین نمونه‌ای از خروجی y به‌صورت نرمال‌سازی‌شده نمایش داده شد تا صحت ساخت داده‌ها (Sanity Check) تأیید گردد. در نتیجه، پس از تکمیل این مرحله، داده‌ها به‌طور کامل برای آموزش مدل‌های عمیق چندگامی آماده شدند.

۵-۴: تعریف مدل LSTM برای پیش‌بینی چندگامی (Multi-step) و تنظیم تابع

خطا

پس از آماده‌سازی داده‌ها در قالب توالی‌های زمانی با پنجره ۳۰ روزه و افق پیش‌بینی ۷ روزه، یک مدل پایه یادگیری عمیق مبتنی بر LSTM برای پیش‌بینی چندگامی تعریف شد. هدف این مدل، نگاشت ورودی سه‌بعدی $[B, T, F]$ شامل ۳۰ گام زمانی و ۱۷ ویژگی به خروجی $[B, 7]$ است تا فروش ۷ روز آینده به‌صورت همزمان پیش‌بینی شود.

معماری مدل

مدل طراحی‌شده شامل بخش‌های زیر است:

- یک لایه LSTM با:

- تعداد ویژگی‌های ورودی : 17
- اندازه حالت پنهان (Hidden size) برابر 128
- تعداد لایه‌ها (num_layers) برابر 2
- Dropout = 0.2 برای کاهش بیش‌برازش
- یک بخش خروجی (Head) به صورت Sequential شامل:
 - LayerNorm برای پایداری آموزش
 - Dropout جهت جلوگیری از overfitting
 - یک لایه خطی (Linear) برای تولید خروجی با ابعاد ۷ (افق پیش‌بینی)

در این طراحی، خروجی نهایی LSTM در آخرین گام زمانی (آخرین روز از پنجره ۳۰ روزه) استخراج شده و به Head داده می‌شود تا بردار پیش‌بینی ۷ روز آینده تولید گردد.

مدل دارای 208,519 پارامتر قابل آموزش است که نشان می‌دهد ظرفیت مناسبی برای یادگیری الگوهای زمانی دارد، در عین حال نسبت به دیتاست بسیار بزرگ پروژه همچنان در محدوده قابل کنترل قرار می‌گیرد. برای اطمینان از صحت پیاده‌سازی، یک بررسی اولیه (Sanity Check) روی یک batch انجام شد و نتیجه نشان داد:

$$\begin{aligned} \text{Pred shape} &= (256, 7) \\ \text{Expected} &= (256, 7) \end{aligned}$$

این خروجی تأیید می‌کند که مدل به درستی برای پیش‌بینی چندگامی تنظیم شده است.

برای آموزش مدل، از تابع خطای SmoothL1Loss استفاده شد که نسبت به MSE در برابر نقاط پرت پایدارتر بوده و برای داده‌هایی مانند فروش که ممکن است دارای جهش‌های شدید باشد انتخاب مناسبی است. همچنین بهینه‌ساز AdamW با نرخ یادگیری $1e-3$ و weight decay برابر $1e-4$ به کار گرفته شد تا همگرایی مناسب و کنترل overfitting به‌طور همزمان فراهم شود.

۵-۵: تعریف مدل LSTM برای پیش‌بینی چندگامی (Multi-step) و تنظیم تابع خطا

پس از تعریف معماری LSTM، فرآیند آموزش مدل برای ۱۰ دوره (Epoch) انجام شد. در هر دوره، ابتدا مدل روی داده‌های آموزش به‌روزرسانی شده و سپس عملکرد آن روی مجموعه اعتبارسنجی محاسبه گردید. معیار بهینه‌سازی در این مرحله SmoothL1Loss بود و برای افزایش پایداری آموزش، از Gradient Clipping با مقدار $CLIP_NORM = 1.0$ استفاده شد تا از انفجار گرادیان‌ها در شبکه‌های بازگشتی جلوگیری شود.

به‌منظور جلوگیری از بیش‌برازش و انتخاب بهترین وزن‌ها، در هر epoch مقدار `val_loss` با بهترین مقدار قبلی مقایسه شد و در صورت بهبود، مدل به‌عنوان بهترین `checkpoint` ذخیره گردید. در نهایت بهترین مدل در فایل `best_lstm.pt` ذخیره شد.

نتایج نشان می‌دهد که مقدار خطای آموزش از حدود 0.2745 در epoch اول به حدود 0.0477 در epoch دهم کاهش یافته است که بیانگر یادگیری مؤثر مدل از داده‌های آموزشی است. همچنین خطای اعتبارسنجی نیز به‌صورت کلی روند کاهشی داشته و بهترین مقدار آن برابر:

$$\text{best_val} = 0.1660$$

به‌دست آمده است) در epoch هشتم. (پس از این نقطه، مقدار `val_loss` در epoch‌های بعدی اندکی افزایش پیدا کرده است (مثلاً ۰.۱۷۵۳ و ۰.۱۷۳۶)، که می‌تواند نشانه شروع بیش‌برازش خفیف باشد. بنابراین انتخاب `checkpoint` با کمترین `val_loss` باعث می‌شود بهترین تعمیم‌پذیری مدل برای داده‌های آینده حفظ گردد.

۵-۶: ارزیابی مدل LSTM روی اعتبارسنجی (مقیاس واقعی فروش)

پس از بارگذاری بهترین `checkpoint (best_lstm.pt)` و انجام پیش‌بینی روی مجموعه اعتبارسنجی، خروجی‌ها از حالت نرمال‌شده به مقیاس واقعی فروش بازگردانده شدند (`inverse transform`) و معیارهای خطا محاسبه شد.

- VAL MAE (overall): 1321.27
- VAL RMSE (overall): 1937.95

MAE per step: [1271.57, 1288.65, 1306.81, 1310.91, 1331.64, 1353.45, 1385.87] •
RMSE per step: [1878.45, 1900.44, 1924.02, 1922.51, 1947.04, 1977.33, 2012.41] •

این نتایج نشان می‌دهد با افزایش افق پیش‌بینی، خطا به‌صورت تدریجی افزایش پیدا می‌کند (اثر دشوارتر شدن پیش‌بینی در روزهای دورتر).

همچنین نمونه‌های چاپ‌شده از مقادیر واقعی و پیش‌بینی‌شده نشان می‌دهد مدل در برخی بازه‌ها اختلاف قابل توجهی دارد، که می‌تواند ناشی از جهش‌های ناگهانی فروش یا رویدادهایی باشد که به‌طور کامل در ویژگی‌ها منعکس نشده‌اند.

همچنین نمونه‌های چاپ‌شده از مقادیر واقعی و پیش‌بینی‌شده نشان می‌دهد مدل در برخی بازه‌ها اختلاف قابل توجهی دارد، که می‌تواند ناشی از جهش‌های ناگهانی فروش یا رویدادهایی باشد که به‌طور کامل در ویژگی‌ها منعکس نشده‌اند.