



پروژه درس یادگیری ماشین

پروژه شماره ۴: پیش‌بینی فروش آتی فروشگاه‌های زنجیره‌ای Rossman

نگارش

محمدامین رضائی

محمد مهدی رنجبر

سید جلال‌الدین طباطبایی

استاد درس

دکتر شریفی زارچی

اسفند ۱۴۰۴

دانشگاه صنعتی شریف، دانشکده مهندسی برق

به یاد:

تمام جاویدنام‌هایی که در راه آزادی جانشان را فدای میهن کردند.

چکیده

این پروژه بر پایه داده‌های فروش روزانه بیش از ۱۱۰۰ شعبه فروشگاه‌های زنجیره‌ای Rossmann و شامل بیش از یک میلیون رکورد طراحی شده است. هدف آن، توسعه مدلی مبتنی بر یادگیری ماشین برای پیش‌بینی دقیق فروش هر فروشگاه و شناسایی عوامل اثرگذار بر عملکرد فروش است. حجم و تنوع بالای داده‌ها، ضمن فراهم کردن بستر مناسب برای تحلیل‌های پیشرفته، چالش‌هایی در زمینه پردازش و مدل‌سازی ایجاد می‌کند که در این پژوهش به صورت نظام‌مند به آن‌ها پرداخته شده است.

مقدمه

پروژه حاضر با تمرکز بر داده‌های فروش فروشگاه‌های زنجیره‌ای Rossmann طراحی شده است. این داده‌ها که از رقابت پیش‌بینی فروش این شرکت استخراج شده‌اند، شامل بیش از یک میلیون رکورد فروش روزانه برای بیش از ۱۱۰۰ فروشگاه هستند. چنین حجم و تنوعی از داده، فرصت ارزشمندی برای تحلیل‌های پیشرفته فراهم می‌کند و در عین حال، چالش‌های متعددی در زمینه پردازش، مهندسی ویژگی، مدل‌سازی و ارزیابی ایجاد می‌نماید. هدف اصلی این پروژه، توسعه یک مدل یادگیری ماشین است که بتواند فروش روزانه هر فروشگاه را با دقت بالا پیش‌بینی کرده و در کنار آن، تحلیل دقیقی از عوامل مؤثر بر عملکرد فروش ارائه دهد.

داده‌های مورد استفاده در این پروژه ترکیبی از متغیرهای عددی، طبقه‌ای و زمانی هستند. علاوه بر ستون هدف (Sales)، اطلاعاتی مانند نوع فروشگاه، فاصله از رقبای، نوع و مدت زمان برگزاری پروموشن‌ها، تعطیلات رسمی (StateHoliday)، تعطیلات مدارس (SchoolHoliday)، و ویژگی‌های تقویمی (روز هفته، ماه، فصل و ...) در اختیار قرار دارند. همچنین فایل جانبی store.csv شامل مشخصات ساختاری هر فروشگاه است که امکان تحلیل عمیق‌تر و ترکیب داده‌های سطح فروشگاه با داده‌های زمانی را فراهم می‌کند. این تنوع ویژگی‌ها، بستر مناسبی برای استخراج الگوهای رفتاری فروش در بازه‌های زمانی مختلف و شرایط متفاوت محیطی ایجاد می‌کند.

رویکرد این پروژه به صورت مرحله‌ای و ساختارمند طراحی شده است. در گام نخست، تحلیل اکتشافی داده‌ها (Data Visualization) با هدف درک الگوهای اولیه، روندهای زمانی، اثر تعطیلات و پروموشن‌ها و مقایسه عملکرد فروشگاه‌های مختلف انجام می‌شود. این مرحله نقش اساسی در شناخت رفتار داده‌ها، شناسایی ناهنجاری‌ها و کشف روابط پنهان میان متغیرها ایفا می‌کند. بررسی همبستگی متغیرها و تحلیل روند فروش در طول زمان، دیدی روشن از ساختار مسئله و پیچیدگی‌های آن ارائه می‌دهد. در مرحله بعد، مهندسی ویژگی و آماده‌سازی داده‌ها (Feature Engineering) به عنوان یکی از حیاتی‌ترین بخش‌های پروژه انجام می‌شود. در مسائل پیش‌بینی سری‌های زمانی، کیفیت ویژگی‌های استخراج‌شده تأثیر مستقیمی بر عملکرد مدل دارد. در این پروژه، با ترکیب جدول فروش با اطلاعات فروشگاه‌ها بر اساس Store ID، ویژگی‌های زمانی جدید (مانند روز هفته، ماه، فصل)، ویژگی‌های تأخیری (lag features)، میانگین‌های متحرک، آمارهای تجمعی و حتی مؤلفه‌های دورهای مانند Fourier terms استخراج می‌شوند. همچنین مدیریت داده‌های گمشده، نرمال‌سازی، و تفکیک داده‌ها به مجموعه‌های آموزش، اعتبارسنجی و آزمون با حفظ ترتیب زمانی انجام می‌گیرد تا از نشت اطلاعات جلوگیری شود.

پس از آماده‌سازی داده‌ها، مرحله آموزش و ارزیابی مدل‌ها (Learn & Estimate) آغاز می‌شود. در این فاز، ابتدا یک مدل پایه (Baseline) ساده برای ایجاد معیار مقایسه پیاده‌سازی می‌شود و سپس مدل‌های پیشرفته‌تری

مانند XGBoost و LightGBM با تنظیم ابرپارامترها آموزش داده می‌شوند. استفاده از اعتبارسنجی زمانی مبتنی بر فروشگاه (store-aware CV) و گزارش معیارهایی مانند Root Mean Squared Error (RMSE) امکان ارزیابی منصفانه عملکرد مدل را فراهم می‌سازد. علاوه بر این، تحلیل اهمیت ویژگی‌ها با استفاده از SHAP انجام می‌شود تا نقش هر متغیر در پیش‌بینی فروش به صورت شفاف تفسیر گردد. این بخش به مدیران کمک می‌کند تا درک بهتری از عوامل کلیدی تأثیرگذار بر فروش داشته باشند.

در ادامه، پروژه وارد فاز تحلیل عدم قطعیت و طبقه‌بندی فروش می‌شود. در این بخش، علاوه بر پیش‌بینی نقطه‌ای فروش، تلاش می‌شود میزان عدم قطعیت پیش‌بینی‌ها با روش‌هایی مانند quantile regression و estimation ensemble برآورد شود. همچنین فروش به کلاس‌های مختلف (کم، متوسط، زیاد) تقسیم شده و یک مدل طبقه‌بندی چندکلاسه با معیارهایی مانند ROC-AUC و F1 Score آموزش داده می‌شود. این رویکرد، دیدی تکمیلی از وضعیت فروش ارائه داده و به تصمیم‌گیری در شرایط عدم اطمینان کمک می‌کند. در نهایت، در فاز عمیق پروژه (Deep Section)، مدل‌های یادگیری عمیق مانند LSTM و TCN برای پیش‌بینی چندگامی (multi-step forecasting) و تخمین عدم قطعیت مورد استفاده قرار می‌گیرند. بهینه‌سازی ابرپارامترها با ابزارهایی مانند Optuna یا Ray Tune انجام شده و نتایج با مدل‌های کلاسیک مقایسه می‌شوند. این بخش نشان‌دهنده ظرفیت روش‌های پیشرفته در استخراج الگوهای پیچیده زمانی و بهبود عملکرد پیش‌بینی است.


فاز ۱: Data Visualization - تحلیل اکتشافی و شناخت داده‌ها

در این مرحله، ابتدا داده‌های اصلی پروژه شامل فایل `train.csv` (اطلاعات فروش روزانه فروشگاه‌ها) و فایل `store.csv` (ویژگی‌های ساختاری هر فروشگاه) بارگذاری شدند. ستون تاریخ به صورت مستقیم به فرمت زمانی (`datetime`) تبدیل شد تا امکان انجام تحلیل‌های سری زمانی و استخراج ویژگی‌های تقویمی فراهم گردد. پس از بارگذاری، دو مجموعه داده بر اساس شناسه فروشگاه (`Store`) با یکدیگر ادغام شدند تا یک دیتافریم جامع شامل اطلاعات فروش و مشخصات فروشگاه‌ها ایجاد شود. نتیجه این ادغام، دیتاستی با ابعاد ۱۰۰۱۵۹۹ سطر و ۲۳ ستون است.

به منظور تقویت قدرت تحلیلی داده‌ها، چندین ویژگی زمانی از ستون `Date` استخراج شد که شامل سال، ماه، روز و شماره هفته در سال است. این ویژگی‌ها امکان بررسی روندهای فصلی، چرخه‌های هفتگی و تغییرات سالانه فروش را فراهم می‌کنند. همچنین ستون `StateHoliday` که دارای مقادیر عددی و متنی بود، به نوع رشته‌ای تبدیل شد و مقدار «۰» به `Regular_Day` تغییر یافت تا تحلیل روزهای تعطیل و غیرتعطیل به صورت شفاف‌تری انجام شود. برای انجام تحلیل اکتشافی دقیق‌تر، تنها رکوردهای مربوط به روزهایی که فروشگاه باز بوده (`Open = 1`) مقدار فروش آن‌ها بزرگ‌تر از صفر بوده است انتخاب شدند. این فیلتر باعث حذف روزهای تعطیلی فروشگاه و داده‌های غیرموثر در تحلیل روند واقعی فروش گردید.

۱-۱: تحلیل روند فروش در طول زمان

به منظور بررسی الگوهای زمانی و تشخیص رفتار فصلی فروش، روند فروش چهار فروشگاه منتخب (۱، ۸۵، ۲۵۹، ۵۱۲) در بازه زمانی ۲۰۱۳ تا ۲۰۱۵ مورد تحلیل قرار گرفت. برای کاهش نویزهای روزانه و نمایش روندهای کلی‌تر، داده‌های فروش به صورت میانگین هفتگی (`Weekly Average`) بازنمونه‌گیری (`Resample`) شدند.



- فروشگاه‌هایی مانند Store 259 و Store 512 روند کلی افزایشی در طول زمان نشان می‌دهند که می‌تواند ناشی از رشد بازار، افزایش تقاضا یا بهبود عملکرد عملیاتی باشد.

- تفاوت قابل توجهی در سطح میانگین فروش هفتگی بین فروشگاه‌ها مشاهده می‌شود. به طور مثال، Store 259 به طور پیوسته بالاترین سطح فروش را دارد، در حالی که Store 1 کمترین سطح فروش را در میان فروشگاه‌های منتخب نشان می‌دهد. این موضوع اهمیت در نظر گرفتن ویژگی‌های اختصاصی هر فروشگاه در مدل‌سازی را نشان می‌دهد.

- وجود نوسانات دوره‌ای (Seasonality) الگوهای تکرارشونده در طول سال، به ویژه افزایش فروش در برخی بازه‌های زمانی خاص، نشان‌دهنده وجود مؤلفه فصلی در داده‌ها است. این موضوع اهمیت استخراج ویژگی‌های زمانی مانند ماه، هفته سال و تعطیلات را در مراحل بعدی پروژه توجیه می‌کند.

- ویژگی‌های زمانی (به ویژه در سال ۲۰۱۵)، دامنه نوسانات افزایش یافته است که می‌تواند ناشی از کمپین‌های تبلیغاتی، تغییرات تقاضا یا شرایط اقتصادی باشد.

به طور کلی، نتایج این بخش نشان می‌دهد که داده‌های فروش دارای ساختار سری زمانی، روند (Trend) و مؤلفه‌های فصلی (Seasonality) هستند. بنابراین، در مراحل بعدی مدل‌سازی، استفاده از ویژگی‌های زمانی، lag features و روش‌های مناسب سری زمانی کاملاً ضروری خواهد بود.

۲-۱: تحلیل روند فروش در طول زمان

به منظور بررسی اثر متغیرهای کلیدی بر میزان فروش، سه عامل مهم شامل Promo، StateHoliday و SchoolHoliday مورد تحلیل قرار گرفتند. نتایج در قالب نمودارهای مقایسه‌ای و توزیعی نمایش داده شده‌اند.



تحلیل تأثیر متغیرهای Promo، StateHoliday و SchoolHoliday بر میزان فروش

- **تأثیر Promo بر فروش**

بر اساس نمودار مقایسه‌ای، میانگین فروش در روزهایی که پروموشن فعال بوده ($Promo=1$) به‌طور قابل توجهی بالاتر از روزهای عادی ($Promo=0$) است. اختلاف محسوس میان دو ستون نشان می‌دهد که اجرای کمپین‌های تبلیغاتی و تخفیف‌ها تأثیر مستقیم و معناداری بر افزایش فروش داشته است. این نتیجه بیانگر آن است که متغیر **Promo** یکی از مهم‌ترین ویژگی‌های پیش‌بینی فروش خواهد بود و انتظار می‌رود در مدل‌های یادگیری ماشین دارای اهمیت بالایی باشد.

- **تأثیر تعطیلات رسمی (StateHoliday)**

نمودار جعبه‌ای (Boxplot) توزیع فروش را در انواع مختلف تعطیلات رسمی نشان می‌دهد. نتایج نشان می‌دهد که سطح فروش و پراکندگی آن در انواع مختلف تعطیلات متفاوت است. در برخی تعطیلات (به‌ویژه تعطیلات بزرگ)، نوسانات فروش افزایش یافته و مقادیر پرت بیشتری مشاهده می‌شود. این موضوع نشان‌دهنده رفتار متفاوت مشتریان در دوره‌های خاص سال است. وجود توزیع‌های متفاوت و افزایش واریانس در برخی تعطیلات، اهمیت مدل‌سازی اثر تعطیلات را در پیش‌بینی فروش تقویت می‌کند.

- **تأثیر تعطیلات مدارس (SchoolHoliday)**

مقایسه میانگین فروش در روزهای تعطیلی مدارس نشان می‌دهد که فروش در این بازه‌ها اندکی افزایش یافته است. این موضوع می‌تواند ناشی از افزایش حضور خانواده‌ها در فروشگاه‌ها در زمان تعطیلی مدارس باشد. اگرچه اختلاف میانگین فروش در این متغیر به اندازه **Promo** چشمگیر نیست، اما همچنان نشان می‌دهد که **SchoolHoliday** یک متغیر تأثیرگذار در رفتار فروش است و باید در مدل لحاظ شود.

۳-۱: تحلیل همبستگی بین متغیرها

به منظور بررسی روابط خطی میان متغیرهای عددی و شناسایی عوامل اثرگذار بر فروش، ماتریس همبستگی پیرسون بین ویژگی‌های منتخب محاسبه و به صورت نقشه حرارتی (Heatmap) نمایش داده شد.




نتایج نشان می‌دهد که تعداد مشتریان قوی‌ترین همبستگی مثبت را با فروش (0.90) دارد که بیانگر نقش مستقیم حضور مشتریان در افزایش درآمد است. همچنین متغیرهای Open (0.68) و Promo (0.45) دارای همبستگی مثبت قابل توجه با فروش هستند که تأثیر باز بودن فروشگاه و اجرای پروموشن‌ها را تأیید می‌کند. در مقابل، DayOfWeek دارای همبستگی منفی متوسط (-0.46) است که وجود الگوی هفتگی در فروش را نشان می‌دهد. سایر متغیرها مانند CompetitionDistance و Year همبستگی خطی قابل توجهی با فروش

نشان نمی‌دهند. به‌طور کلی، نتایج این بخش اهمیت متغیرهای مشتریان، پروموشن و الگوهای زمانی را در مدل‌سازی فروش تأیید می‌کن.

۴-۱: مقایسه عملکرد فروش بر اساس نوع فروشگاه

به‌منظور بررسی تفاوت عملکرد فروشگاه‌ها، میانگین فروش بر اساس نوع فروشگاه (a, b, c, d) محاسبه و مقایسه شد.



نتایج نشان می‌دهد که فروشگاه‌های نوع b با میانگین فروش حدود ۱۰۲۲۸ بالاترین عملکرد را دارند و فاصله قابل توجهی با سایر انواع فروشگاه‌ها نشان می‌دهند. در مقابل، فروشگاه‌های انواع a, c و d میانگین فروشی در بازه تقریباً ۶۸۰۰ تا ۷۰۰۰ دارند و اختلاف آن‌ها نسبتاً کم است. این تفاوت بیانگر آن است که نوع فروشگاه یکی از عوامل ساختاری اثرگذار بر سطح فروش بوده و باید در فرآیند مدل‌سازی به‌عنوان یک ویژگی مهم در نظر گرفته شود.

فاز ۲: Feature Engineering - مهندسی ویژگی و آماده‌سازی داده

پس از انجام تحلیل اکتشافی داده‌ها و شناسایی الگوهای زمانی و اثر متغیرهای کلیدی بر فروش، در این مرحله تمرکز پروژه بر غنی‌سازی داده‌ها و آماده‌سازی آن‌ها برای مدل‌سازی قرار گرفت. در مسائل پیش‌بینی سری زمانی، کیفیت و طراحی ویژگی‌ها نقش تعیین‌کننده‌ای در عملکرد مدل‌های یادگیری ماشین دارد؛ از این رو، مهندسی ویژگی به‌عنوان یکی از حیاتی‌ترین مراحل پروژه در نظر گرفته شد. در این فاز، ابتدا جداول فروش و اطلاعات فروشگاه‌ها بر اساس شناسه Store ID ترکیب شدند تا یک دیتاست جامع شامل ویژگی‌های زمانی و ساختاری ایجاد شود. سپس مجموعه‌ای از ویژگی‌های زمانی جدید شامل روز هفته، ماه، فصل و سایر شاخص‌های تقویمی استخراج گردید تا الگوهای فصلی و چرخه‌ای فروش بهتر مدل‌سازی شوند. علاوه بر ویژگی‌های تقویمی، ویژگی‌های وابسته به گذشته (Lag Features) و آمارهای متحرک نظیر میانگین و انحراف معیار فروش در بازه‌های زمانی مختلف ایجاد شدند. این ویژگی‌ها به مدل امکان می‌دهند وابستگی‌های زمانی و حافظه کوتاه‌مدت فروش را درک کند. همچنین برای مدل‌سازی مؤلفه‌های دورهای، از ویژگی‌های تناوبی نظیر Fourier terms استفاده شد. در ادامه، داده‌های گمشده مدیریت و در صورت نیاز نرمال‌سازی انجام شد تا مقیاس متغیرها برای مدل‌های مختلف مناسب باشد. در نهایت، داده‌ها با حفظ ترتیب زمانی به مجموعه‌های آموزش، اعتبارسنجی و آزمون تقسیم شدند تا از نشت اطلاعات جلوگیری شده و ارزیابی مدل به‌صورت واقع‌گرایانه انجام گیرد.

۱-۲: بارگذاری، ادغام و فیلتر داده‌ها

در ابتدای فرآیند مهندسی ویژگی، داده‌های فروش (train.csv) و اطلاعات فروشگاه‌ها (store.csv) مجدداً بارگذاری شدند. سپس دو جدول بر اساس شناسه فروشگاه (Store) با یکدیگر ادغام گردیدند تا یک دیتاست یکپارچه شامل اطلاعات فروش روزانه و ویژگی‌های ساختاری فروشگاه‌ها ایجاد شود. به‌منظور افزایش دقت مدل‌سازی و حذف داده‌های غیرمؤثر، تنها رکوردهای مربوط به روزهایی که فروشگاه باز بوده ($Open = 1$) و مقدار فروش آن‌ها بزرگ‌تر از صفر بوده است نگه داشته شدند. این فیلتر باعث حذف روزهای تعطیلی و داده‌های بدون فروش شده و تمرکز تحلیل را بر رفتار واقعی فروش حفظ می‌کند. در نهایت، داده‌ها بر اساس شناسه فروشگاه و تاریخ مرتب‌سازی شدند. این مرحله برای ایجاد صحیح ویژگی‌های تأخیری (Lag Features) و محاسبات وابسته به زمان کاملاً ضروری است، زیرا ترتیب زمانی داده‌ها باید حفظ شود تا از بروز خطا و نشت اطلاعات جلوگیری گردد.

۲-۲: ایجاد ویژگی‌های زمانی

با توجه به ماهیت سری زمانی مسئله پیش‌بینی فروش، استخراج ویژگی‌های زمانی یکی از مهم‌ترین مراحل مهندسی ویژگی محسوب می‌شود. در این بخش، مجموعه‌ای از متغیرهای تقویمی از ستون تاریخ (Date) استخراج گردید که شامل سال، ماه، روز، روز هفته و شماره هفته سال است. این ویژگی‌ها امکان مدل‌سازی الگوهای فصلی، چرخه‌های هفتگی و تغییرات دوره‌های فروش را فراهم می‌کنند. همچنین متغیر IsWeekend ایجاد شد تا روزهای پایانی هفته (شنبه و یکشنبه) از سایر روزها تفکیک شوند. این ویژگی می‌تواند رفتار متفاوت مشتریان در آخر هفته را برای مدل آشکار کند. علاوه بر ویژگی‌های تقویمی، به‌منظور در نظر گرفتن اثر رقبا، مدت زمان فعالیت رقبا نیز محاسبه شد. ابتدا تاریخ شروع فعالیت رقبا بر اساس اطلاعات سال و ماه ثبت‌شده ساخته شد و سپس تعداد روزهای سپری‌شده از زمان شروع فعالیت رقبا تا هر تاریخ محاسبه گردید (CompetitionDaysOpen). این متغیر نشان می‌دهد که حضور طولانی‌تر رقبا ممکن است چگونه بر فروش فروشگاه اثر بگذارد. در مجموع، این مرحله باعث غنی‌تر شدن داده‌ها از نظر اطلاعات زمانی و محیط رقابتی شده و بستر مناسبی برای مدل‌سازی دقیق‌تر فراهم می‌کند.


۲-۳: ایجاد ویژگی‌های تأخیری و آمارهای متحرک (Lag & Rolling Features)

به‌منظور مدل‌سازی وابستگی زمانی فروش و در نظر گرفتن حافظه کوتاه‌مدت داده‌ها، مجموعه‌ای از ویژگی‌های تأخیری (Lag Features) و آمارهای متحرک ایجاد شد. از آنجا که فروش هر روز به میزان فروش روزهای قبل وابسته است، این ویژگی‌ها نقش مهمی در افزایش قدرت پیش‌بینی مدل دارند. در این بخش، برای هر فروشگاه به‌صورت مجزا و با حفظ ترتیب زمانی، فروش روزهای گذشته محاسبه شد. به‌طور مشخص، مقادیر فروش با تأخیرهای ۱ روزه، ۲ روزه و ۷ روزه (Sales_Lag1، Sales_Lag2 و Sales_Lag7) ایجاد گردید. استفاده از تأخیر ۷ روزه به مدل کمک می‌کند الگوهای هفتگی تکرارشونده را درک کند. علاوه بر آن، آمارهای متحرک شامل میانگین متحرک ۷ روزه (Sales_RollMean7) و انحراف معیار متحرک ۷ روزه (Sales_RollStd7) محاسبه شدند. این ویژگی‌ها اطلاعاتی درباره سطح متوسط فروش اخیر و میزان نوسانات آن در اختیار مدل قرار می‌دهند. نکته مهم در این مرحله، اعمال عملگر shift قبل از محاسبه میانگین و انحراف معیار است تا از نشت اطلاعات (Data Leakage) جلوگیری شود؛ بدین معنا که در پیش‌بینی هر روز، تنها از اطلاعات گذشته استفاده گردد. در نهایت، رکوردهایی که به دلیل ایجاد تأخیرها دارای مقادیر گم‌شده بودند حذف شدند تا داده‌ها برای ورود به مرحله مدل‌سازی آماده شوند.

۴-۲: افزودن مؤلفه‌های فوریه برای مدل‌سازی فصلی بودن (Fourier Terms)


به‌منظور مدل‌سازی دقیق‌تر الگوهای تناوبی و فصلی در داده‌های فروش، از تبدیلات فوریه استفاده شد. در مسائل سری زمانی، بسیاری از الگوهای فصلی به‌صورت دوره‌ای و غیرخطی ظاهر می‌شوند و استفاده از توابع سینوسی و کسینوسی امکان نمایش پیوسته این چرخه‌ها را فراهم می‌کند.

در این بخش، دو نوع تناوب اصلی در داده‌ها مدل‌سازی شد:

• 

با استفاده از توابع سینوس و کسینوس بر اساس روز هفته، مؤلفه‌های `day_sin` و `day_cos` ایجاد شدند.

این ویژگی‌ها به مدل کمک می‌کنند الگوی تکرارشونده فروش در طول هفته را بدون ایجاد گسستگی عددی (مانند فاصله بین روز ۶ و ۰) درک کند.

• 

با استفاده از شماره روز در سال، ویژگی‌های `year_sin` و `year_cos` ساخته شدند تا چرخه‌های سالانه و تغییرات فصلی بلندمدت در فروش مدل‌سازی شوند.

استفاده از ویژگی‌های فوریه به مدل اجازه می‌دهد رفتارهای فصلی را به‌صورت نرم و پیوسته یاد بگیرد و نسبت به استفاده صرف از متغیرهای گسسته زمانی، عملکرد بهتری در پیش‌بینی ارائه دهد.

۵-۲: پیش‌پردازش نهایی داده‌ها (Encoding, Imputation & Scaling)

در این مرحله، داده‌ها برای ورود به مدل‌های یادگیری ماشین آماده‌سازی نهایی شدند. ابتدا مقادیر گمشده در متغیر `CompetitionDistance` با استفاده از مقدار میانه (`Median`) جایگزین شدند تا اثر داده‌های پرت کاهش یابد. سپس سایر مقادیر گمشده احتمالی با مقدار صفر پر شدند تا ساختار داده‌ها کامل گردد.

در ادامه، متغیرهای طبقه‌ای شامل `StateHoliday`، `StoreType` و `Assortment` با استفاده از روش `Label Encoding` به مقادیر عددی تبدیل شدند. این تبدیل برای استفاده از این متغیرها در مدل‌های یادگیری ماشین ضروری است. در نهایت، برخی از ویژگی‌های عددی مهم شامل `CompetitionDistance`، `CompetitionDaysOpen`، `Sales_RollMean7` و `Sales_RollStd7` با استفاده از روش `MinMax Scaling` به بازه `[0,1]` نرمال‌سازی شدند. این کار باعث هم‌مقیاس شدن متغیرها و بهبود پایداری و عملکرد مدل، به‌ویژه در الگوریتم‌های حساس به مقیاس داده‌ها، می‌شود. با تکمیل این مرحله، داده‌ها از نظر ساختاری و عددی آماده ورود به فاز مدل‌سازی شدند.

۶-۲: تفکیک زمانی داده‌ها (Time-Series Split)

بر این اساس، داده‌ها به سه بخش تقسیم شدند:

- مجموعه آموزش (Training Set): شامل ۷۴۵,۳۲۲
- مجموعه اعتبارسنجی (Validation Set): شامل ۳۶,۳۷۶
- مجموعه آزمون (Test Set): شامل ۴۱,۴۱۵

برای ارزیابی واقع‌گرایانه مدل، شش هفته پایانی به‌عنوان مجموعه آزمون و شش هفته قبل از آن به‌عنوان مجموعه اعتبارسنجی در نظر گرفته شد. در ادامه، ستون هدف (Sales) از سایر ویژگی‌ها جدا شد و متغیرهایی که ممکن بود موجب نشت اطلاعات شوند مانند Date، Customer و Open از مجموعه ویژگی‌ها حذف گردیدند. در نهایت، ۲۷ ویژگی مهندسی‌شده به‌عنوان ورودی نهایی مدل انتخاب شدند که شامل ویژگی‌های زمانی، تأخیری، آماری، رقابتی و مؤلفه‌های فوریه هستند.

فاز ۳: Learn & Estimate - آموزش و ارزیابی مدل‌ها

پس از تکمیل فرآیند مهندسی ویژگی و آماده‌سازی داده‌ها، در این مرحله مدل‌های پیش‌بینی فروش توسعه و ارزیابی شدند. هدف اصلی این فاز، ساخت مدلی با دقت بالا برای پیش‌بینی فروش روزانه هر فروشگاه و مقایسه عملکرد الگوریتم‌های مختلف یادگیری ماشین بود. در ابتدا یک مدل پایه (Baseline) به‌منظور ایجاد معیار مقایسه پیاده‌سازی شد. سپس مدل‌های پیشرفته‌تر از جمله الگوریتم‌های مبتنی بر گرادیان بوستینگ مانند XGBoost و LightGBM آموزش داده شدند. برای جلوگیری از نشت اطلاعات و ارزیابی واقع‌گرایانه، از تقسیم زمانی داده‌ها و اعتبارسنجی مناسب سری زمانی استفاده شد. عملکرد مدل‌ها با استفاده از معیار Root Mean Squared Error (RMSE) ارزیابی گردید و علاوه بر آن، تحلیل اهمیت ویژگی‌ها و بررسی خطاها به‌منظور درک بهتر رفتار مدل انجام شد.

در ابتدای فاز مدل‌سازی، مراحل اصلی پیش‌پردازش و مهندسی ویژگی فاز قبل به‌صورت یکپارچه مجدداً اجرا شد تا داده‌ها به شکل نهایی و قابل استفاده برای آموزش مدل‌ها آماده شوند. این مراحل شامل ادغام داده‌های فروش و اطلاعات فروشگاه‌ها، استخراج ویژگی‌های زمانی، ایجاد ویژگی‌های تأخیری (Lag) و میانگین متحرک، مدیریت داده‌های گمشده و کدگذاری متغیرهای طبقه‌ای بود. پس از تکمیل پیش‌پردازش، داده‌ها به‌صورت زمانی و بدون اختلاط آینده با گذشته تقسیم شدند؛ به‌طوری‌که شش هفته پایانی به‌عنوان مجموعه آزمون و شش هفته قبل از آن به‌عنوان مجموعه اعتبارسنجی در نظر گرفته شد. این رویکرد ارزیابی واقع‌گرایانه‌تری از عملکرد مدل فراهم می‌کند.

در نهایت، ماتریس ویژگی‌ها و متغیر هدف استخراج شد. ابعاد نهایی داده‌ها به شرح زیر است:

- مجموعه آموزش $(745,322 \times 21)$

- مجموعه آزمون $(41,415 \times 21)$

که نشان می‌دهد مدل با ۲۱ ویژگی ورودی آموزش داده خواهد شد.

با تکمیل این مرحله، داده‌ها آماده ورود به بخش آموزش مدل پایه و مدل‌های پیشرفته شدند.

۱-۳: آغاز مدل‌سازی و تعریف معیار ارزیابی

در ابتدای فاز سوم، به‌منظور ورود به مرحله آموزش و ارزیابی مدل‌ها، ابتدا زیرساخت محاسباتی و معیار ارزیابی تعریف شد. برای سنجش عملکرد مدل‌ها از معیار ریشه میانگین مربعات خطا (RMSE) استفاده گردید که یکی از معیارهای استاندارد در مسائل پیش‌بینی فروش و رگرسیون بوده و به دلیل حساسیت به خطاهای بزرگ، مقایسه‌ی مدل‌ها را دقیق‌تر می‌کند. در این پروژه RMSE به صورت مستقیم و با استفاده از روابط ریاضی تعریف و پیاده‌سازی شد تا ارزیابی به شکل کاملاً شفاف و قابل کنترل انجام گیرد.

در ادامه، به عنوان مدل پایه (Baseline) یک مدل رگرسیون خطی به صورت کامل و بدون استفاده از کتابخانه‌های آماده پیاده‌سازی شد. این مدل با استفاده از فرم بسته‌ی معادله نرمال (Normal Equation) آموزش داده می‌شود؛ به این معنا که بردار وزن‌ها از طریق حل رابطه‌ی بسته‌ی کمترین مربعات به دست می‌آید. همچنین برای افزایش پایداری عددی، به جای وارون‌گیری مستقیم از شبه‌وارون (Pseudo-inverse) استفاده شده است تا در شرایطی که ماتریس‌ها تکین یا نزدیک به تکین باشند نیز فرآیند آموزش با خطای محاسباتی مواجهه نشود.

علاوه بر این، امکان استفاده از منظم‌سازی L2 (Ridge Regularization) نیز در مدل در نظر گرفته شد. این منظم‌سازی باعث کنترل بزرگی ضرایب، کاهش بیش‌برازش و افزایش تعمیم‌پذیری مدل به داده‌های جدید می‌شود. همچنین در صورت فعال بودن عرض از مبدأ (Intercept)، این جزء از regularization مستثنا شده است تا تفسیرپذیری و رفتار پایه مدل حفظ گردد. در مجموع، این بخش از کار یک خط مبنا و چارچوب ارزیابی قابل اتکا فراهم می‌کند تا در مراحل بعدی، عملکرد مدل‌های پیشرفته‌تر مانند XGBoost یا LightGBM به شکل منصفانه و عددی با این baseline مقایسه شود.

۳-۲: آموزش و ارزیابی مدل Baseline (رگرسیون خطی)

در این بخش، مدل رگرسیون خطی به عنوان مدل پایه با استفاده از ۲۶ ویژگی عددی آموزش داده شد. عملکرد مدل با معیار RMSE روی داده‌های آموزش، اعتبارسنجی و آزمون ارزیابی گردید.

نتایج به صورت زیر به دست آمد:

Train RMSE: 1509.54 •
Validation RMSE: 1574.16 •
Test RMSE: 1415.15 •

اختلاف کم بین خطای آموزش و اعتبارسنجی نشان می‌دهد مدل دچار بیش‌برازش شدید نشده است. با این حال، مقدار RMSE بیانگر محدودیت مدل خطی در مدل‌سازی روابط پیچیده و غیرخطی موجود در داده‌های فروش است. این نتایج به عنوان خط مبنا برای مقایسه با مدل‌های پیشرفته‌تر در ادامه پروژه در نظر گرفته می‌شود.

Test RMSE = 1415.15 •

۳-۳: آموزش و ارزیابی مدل XGBoost (پیاده‌سازی از صفر)

در این بخش، یک نسخه تقریبی از الگوریتم XGBoost برای رگرسیون با گرادیان مرتبه دوم به صورت کامل و بدون استفاده از کتابخانه‌های آماده پیاده‌سازی شد. در این مدل از درخت‌های تصمیم با رشد عمقی محدود و روش histogram-based برای جستجوی شکاف‌ها استفاده شده است. همچنین برای جلوگیری از بیش‌برازش، پارامترهایی مانند `min_child_weight`، `reg_lambda`، `subsample` و `colsample` در نظر گرفته شدند.

به منظور انتخاب تنظیمات مناسب، دو ترکیب مختلف از ابرپارامترها آزمایش شد.

نتایج مدل‌ها

مدل اول:

Train RMSE = 1480.42 •
Validation RMSE = 1550.52 •

مدل دوم:

Train RMSE = 1427.84 •
Validation RMSE = 1516.13 •

مدل دوم بهترین عملکرد را روی مجموعه اعتبارسنجی داشت. تنظیمات بهینه به صورت زیر به دست آمد:

`n_estimators = 60` •
`learning_rate = 0.08` •
`max_depth = 3` •
`min_child_weight = 80` •
`reg_lambda = 2.0` •
`subsample = 0.5` •
`colsample = 0.5` •

Best Validation RMSE = 1516.13
Test RMSE (Best Model) = 1370.74

مقایسه نتایج با مدل Baseline رگرسیون خطی با ($\text{Validation RMSE} \approx 1574$) نشان می‌دهد که XGBoost توانسته خطا را به میزان قابل توجهی کاهش دهد. این بهبود نشان‌دهنده توانایی مدل در یادگیری روابط غیرخطی و تعامل بین ویژگی‌ها است؛ قابلیت‌هایی که در مدل خطی وجود نداشت. اختلاف بین خطای آموزش و اعتبارسنجی در مدل دوم نسبتاً کنترل شده است، که نشان می‌دهد تنظیمات انتخاب شده منجر به بیش‌برازش شدید نشده‌اند. همچنین کاهش بیشتر خطا روی مجموعه Test (1370) نشان می‌دهد مدل از قدرت تعمیم مناسبی برخوردار است. در مجموع، استفاده از تقویت گرادیانی و تجمیع درخت‌های تصمیم باعث استخراج بهتر الگوهای پیچیده فروش شده و عملکرد مدل نسبت به خط مبنا بهبود یافته است. این مدل به‌عنوان بهترین مدل کلاسیک در ادامه تحلیل‌ها در نظر گرفته می‌شود.

۳-۴ اعتبارسنجی زمانی Store-aware به روش Walk-Forward برای XGBoost

در این بخش، برای ارزیابی واقع‌بینانه‌تر مدل XGBoost پیاده‌سازی شده از صفر، از روش اعتبارسنجی زمانی Walk-Forward به‌صورت Store-aware استفاده شد. در این رویکرد، داده‌ها برای هر فروشگاه به ترتیب زمانی مرتب شده و سپس در هر fold یک پنجره اعتبارسنجی ۴۲ روزه تعریف گردید. همچنین برای جلوگیری از نشت اطلاعات زمانی، یک گپ ۷ روزه بین داده‌های آموزش و اعتبارسنجی لحاظ شد و حداقل تاریخچه لازم برای هر فروشگاه نیز ۶۰ روز در نظر گرفته شد. هدف از این طراحی آن است که ارزیابی مدل مشابه شرایط واقعی پیش‌بینی آینده انجام شود و هم‌زمان تفاوت رفتار فروشگاه‌ها نیز حفظ گردد.

نتایج fold ها

Fold 1 پنجره اعتبارسنجی: ۲۰۱۴-۱۲-۱۸ تا ۲۰۱۵-۰۱-۲۸

Train RMSE: 1327.24 •

Val RMSE: 2028.08 •

Fold 2 پنجره اعتبارسنجی: ۲۰۱۵-۰۱-۲۹ تا ۲۰۱۵-۰۳-۱۱

Train RMSE: 1432.71 •

Val RMSE: 1334.19 •

در نهایت، با تجمیع تمام پیش‌بینی‌های اعتبارسنجی در دو fold و محاسبه RMSE به‌صورت وزن‌دار نسبت به تعداد نمونه‌ها، مقدار زیر به دست آمد:

Overall Store-aware CV RMSE (pooled) = 1671.6 •

نتایج نشان می‌دهد عملکرد مدل در دو پنجره زمانی متفاوت یکسان نیست؛ به‌ویژه در fold اول مقدار خطای اعتبارسنجی به‌طور قابل توجهی بالاتر است. این مسئله می‌تواند ناشی از تفاوت الگوهای فروش در بازه‌های زمانی مختلف (مانند اثر تعطیلات، تغییرات فصلی یا تغییر شدت پروموشن‌ها) باشد و نشان می‌دهد مدل نسبت به برخی بازه‌های زمانی حساسیت دارد. در مقابل، fold دوم RMSE بسیار پایین‌تری دارد و به عملکرد پایدارتر نزدیک‌تر است. بنابراین، استفاده از ارزیابی زمانی Store-aware باعث می‌شود تصویر دقیق‌تری از توان تعمیم مدل در سناریوی واقعی پیش‌بینی ارائه شود و صرفاً به یک split ساده train/validation اکتفا نشود

۳-۵: تحلیل اهمیت ویژگی‌ها با SHAP

در این بخش برای تفسیرپذیری مدل XGBoost منتخب، از روش SHAP (KernelExplainer) استفاده شد تا سهم هر ویژگی در پیش‌بینی فروش مشخص شود. به دلیل پیاده‌سازی مدل به‌صورت from-scratch، از یک تابع predict_fn برای اتصال مدل به SHAP استفاده گردید. برای کاهش هزینه محاسباتی، یک نمونه‌ی تصادفی از داده‌های آموزش به‌عنوان پس‌زمینه (حداکثر ۲۰۰ نمونه) و یک نمونه از داده‌های اعتبارسنجی برای توضیح (حداکثر ۳۰۰ نمونه) انتخاب شد و مقدارهای SHAP محاسبه گردید.

نمودار خلاصه SHAP نشان می‌دهد مهم‌ترین عوامل اثرگذار بر خروجی مدل عمدتاً از نوع ویژگی‌های تأخیری و آماری فروش گذشته هستند. به‌صورت مشخص، ویژگی‌های زیر بیشترین اهمیت را داشته‌اند:

- Sales_Lag1 فروش روز قبل
- Sales_RollMean7 میانگین متحرک ۷ روزه
- Promo وجود پروموشن
- Sales_Lag2 و Sales_Lag7 فروش‌های با تأخیر ۲ و ۷ روز

این موضوع نشان می‌دهد مدل برای پیش‌بینی فروش روز جاری، بیشترین اتکا را به حافظه کوتاه‌مدت فروشگاه و الگوهای نزدیک زمانی دارد؛ یعنی رفتار فروش در چند روز اخیر نقش تعیین‌کننده‌ای در پیش‌بینی دارد.

از طرف دیگر، ویژگی Promo نیز جزء ویژگی‌های مهم است و مطابق نمودار، زمانی که Promo فعال است (مقادیر بالاتر ویژگی)، اغلب SHAP value به سمت مثبت حرکت می‌کند که بیانگر افزایش فروش پیش‌بینی‌شده در روزهای پروموشن است.

ویژگی‌های زمانی مانند DayOfWeek، Day و تبدیل‌های تناوبی (day_sin, day_cos) نیز اثر قابل توجهی دارند و نشان می‌دهند مدل الگوی رفتاری فروش در طول هفته/چرخه زمانی را یاد گرفته است.

در مقابل، ویژگی‌هایی مانند CompetitionDistance، StoreType، SchoolHoliday، Promo2SinceWeek/Year و CompetitionDaysOpen در این نمودار اثر کمتری دارند (پراکندگی نزدیک به صفر)، که می‌تواند به این معنا باشد که در حضور ویژگی‌های قدرتمند مرتبط با فروش گذشته، نقش این متغیرها در تصمیم نهایی مدل محدودتر شده است.

۳-۶: تحلیل خطای روی مجموعه Test

در این بخش، عملکرد نهایی مدل منتخب XGBoost روی مجموعه آزمون به صورت دقیق‌تر تحلیل شد. علاوه بر RMSE، معیارهای MAE و MAPE نیز محاسبه شدند تا تصویر جامع‌تری از خطا ارائه شود.

$$\bullet \quad \text{Test RMSE} = 1370.74$$

$$\bullet \quad \text{MAE} = 906.44$$

$$\bullet \quad \text{MAPE} = 0.1395 (\sim 13.95\%)$$

مقدار MAPE نشان می‌دهد مدل به طور متوسط حدود ۱۴٪ خطای نسبی دارد که برای مسئله پیش‌بینی فروش روزانه در مقیاس فروشگاه‌های بزرگ، عملکرد قابل قبولی محسوب می‌شود.

۱۰ فروشگاه با بیشترین MAE شناسایی شدند. فروشگاه‌هایی مانند ۱۱۱۴، ۸۱۷، ۸۴۲ و ۲۶۲ بالاترین میانگین خطای مطلق را دارند. این موضوع نشان می‌دهد مدل برای برخی فروشگاه‌ها به صورت سیستماتیک عملکرد ضعیف‌تری دارد که می‌تواند ناشی از:

- رفتار فروش غیرعادی،
- نوسانات شدید فروش،
- یا الگوهای خاص محلی باشد که در ویژگی‌ها به خوبی منعکس نشده‌اند.

تحلیل خطا بر اساس Promo:

میانگین خطای مطلق در روزهای بدون پروموشن:

$$\bullet \quad \text{Promo} = 0 : 824$$

در روزهای دارای پروموشن:

$$\bullet \quad \text{Promo} = 1 : 1015$$

خطا در روزهای پروموشن به طور محسوسی بیشتر است. این نشان می‌دهد اگرچه Promo یکی از مهم‌ترین ویژگی‌ها در مدل است، اما شدت اثر آن و میزان افزایش فروش در برخی موارد به طور کامل مدل‌سازی نشده است.

تحلیل خطا بر اساس SchoolHoliday

- بدون تعطیلی مدرسه : ۸۹۳
- با تعطیلی مدرسه : ۹۸۸

افزایش خطا در روزهای تعطیلی مدارس بیانگر آن است که رفتار مشتریان در این روزها متفاوت بوده و مدل در پیش‌بینی این تغییرات با چالش بیشتری مواجه است.

تحلیل خطا بر اساس روز هفته

بیشترین خطا مربوط به:

- شنبه (۶) : ۲۸۸۷
- یکشنبه (۰) : ۱۴۴۸
- جمعه (۵) : ۱۲۳۰

کمترین خطا مربوط به روزهای میانی هفته (سه‌شنبه و چهارشنبه) است. این الگو نشان می‌دهد فروش در آخر هفته‌ها نوسان بیشتری دارد و مدل در این روزها کمتر پایدار عمل می‌کند. کمترین خطا مربوط به روزهای میانی هفته (سه‌شنبه و چهارشنبه) است. این الگو نشان می‌دهد فروش در آخر هفته‌ها نوسان بیشتری دارد و مدل در این روزها کمتر پایدار عمل می‌کند.

۲۰ پیش‌بینی با بیشترین خطا بررسی شدند. در این موارد اختلاف بین مقدار واقعی و پیش‌بینی شده بسیار زیاد بوده (در برخی موارد بیش از ۲۰ هزار واحد فروش). اغلب این موارد:

- در بازه‌های زمانی خاص (ژوئن ۲۰۱۵) رخ داده‌اند،
- مربوط به فروش‌های بسیار بالا هستند،
- عمدتاً در روزهای بدون StateHoliday اتفاق افتاده‌اند.

این موضوع نشان می‌دهد مدل در مواجهه با جهش‌های شدید فروش (spikes) یا الگوهای غیرمنتظره عملکرد ضعیف‌تری دارد.

به‌طور کلی مدل عملکرد قابل قبولی دارد، اما:

- در روزهای پروموشن،
- در تعطیلات مدارس،
- و در آخر هفته‌ها،

خطای بیشتری مشاهده می‌شود. همچنین برخی فروشگاه‌ها به‌صورت سیستماتیک خطای بالاتری دارند که می‌تواند هدفی برای بهبودهای بعدی (مانند مدل‌سازی سلسله‌مراتبی یا افزودن ویژگی‌های خاص فروشگاه) باشد

فاز ۴: Uncertainty and Sales Classification - تحلیل عدم قطعیت و

طبقه بندی فروش

در فازهای پیشین، تمرکز اصلی پروژه بر پیش‌بینی نقطه‌ای (Point Forecast) فروش روزانه هر فروشگاه بود. با این حال، در مسائل واقعی کسب‌وکار، صرفاً دانستن یک مقدار پیش‌بینی‌شده کافی نیست؛ بلکه میزان عدم قطعیت (Uncertainty) و دامنه خطای احتمالی پیش‌بینی نیز اهمیت بالایی دارد. علاوه بر آن، در بسیاری از تصمیمات مدیریتی، دسته‌بندی فروش به سطوح مختلف (کم، متوسط، زیاد) کاربردی‌تر از مقدار دقیق فروش است.

در این فاز، پروژه در سه محور اصلی گسترش یافت:

۱. پیاده‌سازی پیش‌بینی چندگامی (Multi-step Forecasting)
به‌منظور پیش‌بینی فروش در چند روز آینده (مثلاً ۷ روز)، با در نظر گرفتن اثر انتشار خطا در طول زمان.
 ۲. تخمین عدم قطعیت پیش‌بینی‌ها
با استفاده از روش‌هایی مانند Quantile Regression یا رویکردهای Ensemble، دامنه اطمینان برای پیش‌بینی‌ها محاسبه شد تا میزان ریسک تصمیم‌گیری مشخص گردد.
 ۳. طبقه‌بندی فروش به سطوح مختلف
فروش به سه کلاس «کم»، «متوسط» و «زیاد» تقسیم شد و یک مدل طبقه‌بندی چندکلاسه آموزش داده شد. عملکرد مدل با معیارهایی مانند F1-score و ROC-AUC ارزیابی گردید.
- هدف این فاز، افزایش کاربردپذیری مدل در تصمیم‌گیری‌های مدیریتی و ارائه تصویری جامع‌تر از رفتار فروش تحت شرایط مختلف است.

۴-۱ بارگذاری داده‌ها و آماده‌سازی اولیه

در ابتدای فاز چهارم، داده‌های پروژه از فایل‌های `train.csv` و `store.csv` بارگذاری شدند و برای ادامه مراحل پیش‌بینی چندگامه و تحلیل عدم‌قطعیت آماده‌سازی اولیه انجام گرفت. ابتدا وجود فایل‌ها در مسیر کاری بررسی شد تا در صورت عدم بارگذاری، خطای مناسب نمایش داده شود. سپس داده‌های فروش روزانه با ستون تاریخ (Date) به‌صورت تاریخ‌محور خوانده شد و با اطلاعات فروشگاه‌ها بر اساس کلید `Store` ادغام گردید.

پس از ادغام، داده‌ها بر اساس فروشگاه و تاریخ مرتب شدند که این کار برای محاسبه ویژگی‌های سری زمانی مانند lag و rolling در مراحل بعد ضروری است. همچنین برای یکسان‌سازی داده‌ها، مقدار StateHoliday 0 به عنوان روز عادی بازتعریف شد.

خلاصه وضعیت داده‌های بارگذاری شده:

- ابعاد داده فروش (train): (1001599, 10)
- ابعاد اطلاعات فروشگاه (store): (1115, 10)
- ابعاد دیتافریم ادغام شده (df): (1001599, 19)
- بازه زمانی داده‌ها 2013-01-01 تا ۲۰۱۵-۰۷-۱۷

این مرحله، ورودی استاندارد و مرتب‌شده‌ای ایجاد می‌کند تا در ادامه فاز ۴، مدل‌سازی پیش‌بینی چندروزه، برآورد عدم قطعیت و طبقه‌بندی سطح فروش بر مبنای داده‌ای سازگار انجام شود.

۲-۴: پیش‌بینی چندگانه ۷ روزه به روش Recursive با رگرسیون خطی

در این بخش، برای پیاده‌سازی Multi-step Forecasting یک مدل رگرسیون خطی (پیاده‌سازی از صفر) به عنوان baseline آموزش داده شد و سپس پیش‌بینی ۷ روز آینده به روش Recursive روی مجموعه اعتبارسنجی انجام گرفت. در این رویکرد، مدل در هر گام یک مقدار فروش را پیش‌بینی می‌کند و همان مقدار پیش‌بینی شده به عنوان ورودی (به‌ویژه در ویژگی‌های lag) برای گام‌های بعدی استفاده می‌شود؛ بنابراین خطا در طول افق پیش‌بینی می‌تواند به صورت تجمعی منتقل شود. برای آموزش مدل، ابتدا فقط ویژگی‌های عددی انتخاب شدند و ستون‌هایی مانند Id (که می‌تواند غیرمفید یا مستعد ایجاد مشکل در تعمیم باشد) از ورودی حذف شد. در نهایت، مدل با استفاده از ۲۹ ویژگی عددی آموزش داده شد. سپس داده‌های اعتبارسنجی به تفکیک فروشگاه مرتب شدند و برای هر فروشگاه، پیش‌بینی به صورت گام‌به‌گام انجام شد. در هر مرحله مقدار پیش‌بینی شده به عنوان مقدار جدید Sales_Lag1 برای رکورد بعدی همان فروشگاه جایگذاری شد تا رفتار recursive شبیه‌سازی شود.

نتیجه ارزیابی این پیش‌بینی چندگانه روی مجموعه اعتبارسنجی به صورت زیر به دست آمد:

$$\bullet \text{ Validation RMSE (Recursive 7-day forecast) = 1916.80}$$

این مقدار RMSE نسبت به حالت پیش‌بینی یک‌گانه معمولاً بزرگ‌تر است که قابل انتظار می‌باشد، زیرا در روش recursive، خطاهای گام‌های اولیه به مراحل بعد منتقل شده و باعث افزایش عدم دقت در افق‌های دورتر می‌شوند. بنابراین این مدل به عنوان خط مبنا برای مقایسه با روش‌های پیشرفته‌تر پیش‌بینی چندگانه و نیز روش‌های برآورد عدم قطعیت در ادامه فاز ۴ در نظر گرفته می‌شود.

این مقدار RMSE نسبت به حالت پیش‌بینی یک‌گامه معمولاً بزرگ‌تر است که قابل انتظار می‌باشد، زیرا در روش recursive، خطاهای گام‌های اولیه به مراحل بعد منتقل شده و باعث افزایش عدم‌دقت در افق‌های دورتر می‌شوند. بنابراین این مدل به‌عنوان خط مبنا برای مقایسه با روش‌های پیشرفته‌تر پیش‌بینی چندگامه و نیز روش‌های برآورد عدم‌قطعیت در ادامه فاز ۴ در نظر گرفته می‌شود.

۴-۳: برآورد عدم‌قطعیت با (Ensemble (Bootstrap)

در این بخش، برای برآورد عدم‌قطعیت پیش‌بینی فروش از روش Ensemble مبتنی بر Bootstrap استفاده شد. ایده اصلی این است که به‌جای یک مدل، چندین مدل روی نمونه‌های بوت‌استرپ‌شده از داده‌های آموزش یاد بگیرند و سپس پراکندگی خروجی آن‌ها به‌عنوان شاخص عدم‌قطعیت در نظر گرفته شود. ابتدا ۱۵ مدل رگرسیون خطی با نسبت نمونه‌گیری ۰٫۸ از داده‌های آموزش (با جایگذاری) آموزش داده شدند. سپس برای هر مدل، پیش‌بینی چندگامه به‌صورت Recursive روی داده‌های اعتبارسنجی انجام شد. برای ساده‌سازی رفتار recursive، در هر گام فقط ویژگی Sales_Lag1 با مقدار پیش‌بینی‌شده به‌روزرسانی شد (و در صورت منفی شدن پیش‌بینی، مقدار به صفر محدود گردید).

پس از تولید پیش‌بینی‌های همه مدل‌ها، خروجی‌ها تجمیع شدند:

- میانگین پیش‌بینی‌ها به‌عنوان مقدار نهایی (Pred Mean)
- انحراف معیار پیش‌بینی‌ها به‌عنوان شاخص پراکندگی (Pred Std)
- و همچنین بازه پیش‌بینی ۱۰٪ تا ۹۰٪ با استفاده از کوانتایل‌ها به‌عنوان Prediction Interval

با استفاده از میانگین ensemble روی مجموعه اعتبارسنجی، مقدار خطای زیر به‌دست آمد:

$$\bullet \text{ Validation RMSE (Ensemble mean) = 1860.64}$$

این نتیجه نسبت به مدل recursive تک‌مدلی ($\text{RMSE} \approx 1916.80$) بهتر است و نشان می‌دهد تجمیع چند مدل باعث کاهش خطا و افزایش پایداری پیش‌بینی شده است.

در نمودار ارائه‌شده برای یک فروشگاه نمونه، سه مؤلفه نمایش داده شده است:

- فروش واقعی (True Sales)
- میانگین پیش‌بینی (Pred Mean)
- بازه عدم‌قطعیت ۱۰٪–۹۰٪ (ناحیه سایه‌دار)

پهن تر شدن ناحیه ۱۰-۹۰٪ در برخی بازه‌ها نشان می‌دهد مدل‌ها در آن نقاط اختلاف بیشتری دارند؛ بنابراین عدم قطعیت پیش‌بینی در آن روزها بالاتر است (معمولاً در حوالی نوسانات شدید یا تغییر رژیم فروش). در مجموع، این سلول علاوه بر ارائه یک پیش‌بینی چندگامه پایدارتر، امکان گزارش بازه اطمینان برای فروش آینده را نیز فراهم می‌کند که یکی از اهداف اصلی فاز ۴ است.

۴-۴: طبقه‌بندی سطح فروش (Low / Medium / High)

در این بخش، به جای پیش‌بینی مقدار دقیق فروش، مسئله به صورت طبقه‌بندی سه کلاسه تعریف شد تا فروش هر روز در یکی از سه سطح کم، متوسط و زیاد قرار گیرد. برای برچسب‌گذاری کلاس‌ها از کوانتایل‌های داده آموزش استفاده شد؛ به طوری که آستانه‌های ۳۳٪ و ۶۶٪ فروش (q_1 و q_2) محاسبه شد و سپس فروش‌ها به صورت زیر دسته‌بندی شدند:

- **Low:** فروش‌های کمتر یا مساوی q_1

- **Medium:** بین q_1 و q_2

- **High:** بزرگ‌تر از q_2

برای آموزش مدل طبقه‌بندی، از همان ویژگی‌های عددی مرحله قبل استفاده شد و یک مدل Logistic Regression چندکلاسه (Multinomial) با $\text{max_iter}=500$ آموزش داده شد. ارزیابی مدل روی مجموعه اعتبارسنجی انجام گرفت. خروجی گزارش طبقه‌بندی نشان می‌دهد عملکرد مدل در سه کلاس متفاوت است:

- **Low:** Precision = 0.61 ، Recall = 0.66 ، F1 = 0.64

- **Medium:** Precision = 0.50 ، Recall = 0.57 ، F1 = 0.53

- **High:** Precision = 0.68 ، Recall = 0.56 ، F1 = 0.61 17579

معیارهای کلی:

- **Accuracy = 0.59**

- **Macro F1-score = 0.5932**

- **Macro ROC-AUC = 0.7639**

نتایج نشان می‌دهد مدل در تشخیص کلاس‌های Low و High عملکرد بهتری نسبت به کلاس Medium دارد. این اتفاق معمولاً طبیعی است، چون کلاس متوسط مرز مشترک با دو کلاس دیگر دارد و نمونه‌های نزدیک به آستانه‌ها سخت‌تر تفکیک می‌شوند. همچنین مقدار $ROC-AUC \approx 0.76$ نشان می‌دهد مدل از نظر رتبه‌بندی احتمالاتی بین کلاس‌ها توانایی قابل قبولی دارد، حتی اگر دقت نهایی طبقه‌بندی حدود ۵۹٪ باشد. در مجموع، این بخش یک نمای سطح بالا از وضعیت فروش ارائه می‌دهد که می‌تواند برای تصمیم‌گیری‌های عملی (مانند برنامه‌ریزی موجودی یا نیروی انسانی) مفید باشد، خصوصاً زمانی که هدف تعیین سطح فروش باشد نه مقدار دقیق آن.

فاز ۵: Deep - قسمت عمیق پروژه

در فازهای قبلی، با استفاده از مهندسی ویژگی و مدل‌های کلاسیک یادگیری ماشین، XGBoost با دقت مناسب انجام شد و همچنین تحلیل عدم قطعیت و طبقه‌بندی فروش توسعه یافت. با این حال، مدل‌های کلاسیک معمولاً برای استخراج الگوهای پیچیده و بلندمدت سری‌های زمانی به مهندسی ویژگی وابسته‌اند. به همین دلیل، در این فاز از مدل‌های یادگیری عمیق استفاده شد تا وابستگی‌های زمانی پیچیده به صورت مستقیم از داده‌ها یاد گرفته شوند و امکان اجرای پیش‌بینی چندگامی و برآورد عدم قطعیت به شکل دقیق‌تر فراهم گردد. در این فاز، سه محور اصلی دنبال شد:

۱. پیش‌بینی چندگامی (Multi-step Forecasting) با مدل‌های عمیق
با هدف پیش‌بینی فروش چند روز آینده، معماری‌هایی مانند LSTM و TCN به کار گرفته شدند تا وابستگی‌های کوتاه‌مدت و بلندمدت سری زمانی را به صورت موثر مدل‌سازی کنند.
۲. تخمین عدم قطعیت همراه با پیش‌بینی
در کنار پیش‌بینی مقدار فروش، تلاش شد بازه اطمینان پیش‌بینی نیز با استفاده از روش‌های مناسب مدل‌های عمیق (مانند رویکردهای احتمالی یا چندک‌ها) برآورد شود تا خروجی مدل برای تصمیم‌گیری واقعی قابل اتکاتر گردد.
۳. تفسیرپذیری مدل (SHAP/Feature Attribution)
با وجود پیچیدگی مدل‌های عمیق، تحلیل تفسیرپذیری جهت شناخت عوامل اثرگذار بر پیش‌بینی‌ها انجام شد تا مشخص شود مدل چه الگوهایی را مهم‌تر در نظر می‌گیرد و آیا رفتار آن با منطق کسب‌وکار هم‌راستا است.

همچنین برای دستیابی به بهترین عملکرد، تنظیم ابرپارامترها با ابزارهایی مانند Optuna یا Ray Tune انجام گرفت تا پارامترهایی مانند تعداد لایه‌ها، اندازه پنجره زمانی (Lookback)، نرخ یادگیری و اندازه batch بهینه شوند. در نهایت، نتایج مدل‌های عمیق از نظر دقت پیش‌بینی، پایداری در چندگام آینده و کیفیت تخمین عدم قطعیت با مدل‌های کلاسیک مقایسه شد تا مزایا و محدودیت‌های هر رویکرد به صورت شفاف مشخص گردد.

۱-۵: مهندسی ویژگی‌های زمانی و پاک‌سازی روزهای تعطیل

در این مرحله، داده‌ها بر اساس شناسه فروشگاه و تاریخ مرتب‌سازی شدند تا ساختار سری زمانی هر فروشگاه به صورت پیوسته و منظم حفظ شود. سپس روزهایی که فروشگاه بسته بوده است ($Open = 0$) حذف شدند،

زیرا در این روزها معمولاً مقدار فروش صفر است و وجود آن‌ها می‌تواند باعث ایجاد نویز در فرآیند یادگیری مدل‌های پیش‌بینی شود. این فیلتر باعث تمرکز مدل بر رفتار واقعی فروش در روزهای فعال گردید.

پس از این مرحله، مجموعه‌ای از ویژگی‌های زمانی جدید ایجاد شد که شامل سال، ماه، روز، شماره هفته سال، شروع و پایان ماه است. این ویژگی‌ها به مدل کمک می‌کنند الگوهای تقویمی و تغییرات دوره‌های فروش را بهتر درک کند. علاوه بر آن، برای حفظ پیوستگی چرخه‌های فصلی، از کدگذاری تناوبی (Cyclic Encoding) برای ماه و روز هفته استفاده شد (Month_sin/cos و DOW_sin/cos). این روش باعث می‌شود مدل ارتباط بین مقادیر مرزی (مانند ماه ۱۲ و ۱) را به صورت نرم و پیوسته یاد بگیرد. در ادامه، یک ویژگی مرتبط با رقابت ایجاد شد. با استفاده از سال و ماه شروع فعالیت رقبا، مدت زمان فعالیت رقبا به صورت تقریبی بر حسب ماه (CompOpenMonths) محاسبه گردید. مقادیر منفی یا نامعتبر به صفر محدود شدند تا از ورود داده‌های ناسازگار جلوگیری شود.

همچنین متغیر PromoInterval به تعداد ماه‌های فعال پروموشن تبدیل شد (PromoIntervalCount) تا به جای یک مقدار متنی، یک شاخص عددی قابل استفاده در مدل ایجاد شود.

در نهایت، برای برخی متغیرهای عددی مرتبط با رقابت و پروموشن، مقدارهای گم‌شده با استفاده از میانگین جایگزین شدند تا توزیع داده‌ها کمتر تحت تأثیر مقادیر پرت قرار گیرد.

پس از اعمال این مراحل، ابعاد داده‌ها به $(830,972 \times 31)$ رسید که نشان‌دهنده حذف روزهای تعطیل و افزودن ویژگی‌های جدید است. دامنه فروش نیز بین 0 تا ۴۱,۵۵۱ واحد باقی ماند که نشان می‌دهد داده‌ها بدون تحریف مقادیر اصلی برای ورود به مدل‌های عمیق آماده شده‌اند.

۲-۵: پاک‌سازی نهایی، کدگذاری و تفکیک زمانی داده‌ها

در این مرحله، آماده‌سازی نهایی داده‌ها برای آموزش مدل‌های عمیق انجام شد. ابتدا رکوردهایی که مقدار فروش آن‌ها برابر صفر بود حذف شدند، زیرا وجود این مقادیر می‌تواند موجب ناپایداری در فرآیند یادگیری و اختلال در مدل‌سازی توالی‌های زمانی شود. پس از این فیلتر، ابعاد داده‌ها به $(830,918 \times 31)$ کاهش یافت که نشان‌دهنده حذف تعداد محدودی از نمونه‌های غیرمؤثر است.

در ادامه، متغیرهای طبقه‌ای شامل StoreType، Assortment و StateHoliday با استفاده از روش Label Encoding به مقادیر عددی تبدیل شدند تا برای ورود به مدل‌های عصبی قابل استفاده باشند. سپس ستون‌هایی که نقشی در مدل‌سازی نداشتند (مانند Id) حذف شدند.

به منظور جلوگیری از نشت اطلاعات آینده به گذشته، داده‌ها مجدداً بر اساس فروشگاه و تاریخ مرتب‌سازی شدند و تقسیم داده‌ها به صورت زمان‌محور (Time-based split) انجام گرفت. در این تقسیم‌بندی، حدود ۸۰٪ ابتدایی بازه زمانی به عنوان مجموعه آموزش و ۲۰٪ انتهایی به عنوان مجموعه اعتبارسنجی در نظر گرفته شد. نتایج این تفکیک به شرح زیر است:

• Train shape: (664,801 × 30)
• Validation shape: (166,117 × 30)

در نهایت، ۱۷ ویژگی نهایی برای ورود به مدل انتخاب شد که شامل ویژگی‌های زمانی، تناوبی (sin/cos)، رقابتی و مرتبط با پروموشن است. ستون هدف نیز Sales در نظر گرفته شد. این ساختار داده، بستر مناسبی برای ساخت توالی‌های زمانی (Lookback Windows) و آموزش مدل‌های عمیق مانند LSTM و TCN فراهم می‌کند.

۳-۵: ساخت دیتاست توالی برای پیش‌بینی چندگامی و آماده‌سازی

DataLoaderها

برای آموزش مدل‌های یادگیری عمیق مانند LSTM و TCN لازم است داده‌ها به شکل توالی‌های زمانی (Sequence) تبدیل شوند. در این پروژه، مسئله به صورت پیش‌بینی چندگامی (Multi-step Forecasting) تعریف شد؛ به این معنا که مدل با مشاهده فروش و ویژگی‌های ۳۰ روز گذشته، فروش ۷ روز آینده را به صورت همزمان پیش‌بینی می‌کند.

در این مرحله، پارامترهای اصلی ساخت توالی به صورت زیر تنظیم شدند:

- طول پنجره ورودی (LOOKBACK) برابر ۳۰ روز
- افق پیش‌بینی (HORIZON) برابر ۷ روز
- اندازه دسته (BATCH_SIZE) برابر ۲۵۶

برای جلوگیری از نشت اطلاعات و بهبود روند یادگیری شبکه عصبی، ویژگی‌ها و متغیر هدف با استفاده از StandardScaler نرمال‌سازی شدند. نکته مهم این است که مقادیر scaler فقط روی داده‌های آموزش (Train) برازش (fit) شد و سپس همان پارامترها برای تبدیل داده‌های اعتبارسنجی (Validation) استفاده گردید. این کار باعث می‌شود توزیع داده‌های آینده وارد فرآیند آموزش نشود و ارزیابی مدل واقع‌گرایانه باقی بماند.

از آنجا که هر فروشگاه يك سری زمانی مستقل دارد، توالیها store-wise

فروشگاه، پس از مرتب‌سازی بر اساس تاریخ، پنجره‌های لغزان ایجاد شد تا خروجی نهایی به شکل زیر باشد:

- X : آرایه سه‌بعدی با ابعاد $[N, 30, 17]$

- y : آرایه دوبعدی با ابعاد $[N, 7]$

نتیجه ساخت توالی‌ها:

- $X_{\text{train}} = (624,661, 30, 17)$ و $y_{\text{train}} = (624,661, 7)$

- $X_{\text{val}} = (125,977, 30, 17)$ و $y_{\text{val}} = (125,977, 7)$

این ابعاد نشان می‌دهد که تعداد بسیار زیادی نمونه آموزشی از داده‌ها استخراج شده است که برای آموزش شبکه‌های عمیق مناسب بوده و امکان یادگیری الگوهای زمانی را تقویت می‌کند.

در ادامه، یک Dataset سفارشی تعریف شد و داده‌ها در قالب DataLoaderهای PyTorch آماده شدند تا آموزش مدل به‌صورت batch-wise انجام شود. بررسی یک batch نمونه نشان داد:

- Batch X: (256, 30, 17)

- Batch y: (256, 7)

که با تعریف مسئله (ورودی ۳۰ روزه و خروجی ۷ روزه) کاملاً سازگار است. همچنین نمونه‌ای از خروجی y به‌صورت نرمال‌سازی‌شده نمایش داده شد تا صحت ساخت داده‌ها (Sanity Check) تأیید گردد. در نتیجه، پس از تکمیل این مرحله، داده‌ها به‌طور کامل برای آموزش مدل‌های عمیق چندگامی آماده شدند.

۴-۵: تعریف مدل LSTM برای پیش‌بینی چندگامی (Multi-step) و تنظیم تابع

خطا

پس از آماده‌سازی داده‌ها در قالب توالی‌های زمانی با پنجره ۳۰ روزه و افق پیش‌بینی ۷ روزه، یک مدل پایه یادگیری عمیق مبتنی بر LSTM برای پیش‌بینی چندگامی تعریف شد. هدف این مدل، نگاشت ورودی سه‌بعدی $[B, T, F]$ شامل ۳۰ گام زمانی و ۱۷ ویژگی به خروجی $[B, 7]$ است تا فروش ۷ روز آینده به‌صورت همزمان پیش‌بینی شود.

معماری مدل

مدل طراحی‌شده شامل بخش‌های زیر است:

- یک لایه LSTM با:

- تعداد ویژگی‌های ورودی : 17
 - اندازه حالت پنهان (Hidden size) برابر 128
 - تعداد لایه‌ها (num_layers) برابر 2
 - Dropout = 0.2 برای کاهش بیش‌برازش
 - یک بخش خروجی (Head) به صورت Sequential شامل:
 - LayerNorm برای پایدارسازی آموزش
 - Dropout جهت جلوگیری از overfitting
 - یک لایه خطی (Linear) برای تولید خروجی با ابعاد ۷ (افق پیش‌بینی)
- در این طراحی، خروجی نهایی LSTM در آخرین گام زمانی (آخرین روز از پنجره ۳۰ روزه) استخراج شده و به Head داده می‌شود تا بردار پیش‌بینی ۷ روز آینده تولید گردد.

مدل دارای 208,519 پارامتر قابل آموزش است که نشان می‌دهد ظرفیت مناسبی برای یادگیری الگوهای زمانی دارد، در عین حال نسبت به دیتاست بسیار بزرگ پروژه همچنان در محدوده قابل کنترل قرار می‌گیرد. برای اطمینان از صحت پیاده‌سازی، یک بررسی اولیه (Sanity Check) روی یک batch انجام شد و نتیجه نشان داد:

$$\begin{aligned} \text{Pred shape} &= (256, 7) \\ \text{Expected} &= (256, 7) \end{aligned}$$

این خروجی تأیید می‌کند که مدل به درستی برای پیش‌بینی چندگامی تنظیم شده است.

برای آموزش مدل، از تابع خطای SmoothL1 Loss استفاده شد که نسبت به MSE در برابر نقاط پرت پایدارتر بوده و برای داده‌هایی مانند فروش که ممکن است دارای جهش‌های شدید باشد انتخاب مناسبی است. همچنین بهینه‌ساز AdamW با نرخ یادگیری 10^{-3} و weight decay برابر 10^{-4} به کار گرفته شد تا همگرایی مناسب و کنترل overfitting به طور همزمان فراهم شود.

۵-۵: تعریف مدل LSTM برای پیش‌بینی چندگامی (Multi-step) و تنظیم تابع خطا

پس از تعریف معماری LSTM، فرآیند آموزش مدل برای ۱۰ دوره (Epoch) انجام شد. در هر دوره، ابتدا مدل روی داده‌های آموزش به‌روزرسانی شده و سپس عملکرد آن روی مجموعه اعتبارسنجی محاسبه گردید. معیار بهینه‌سازی در این مرحله SmoothL1Loss بود و برای افزایش پایداری آموزش، از Gradient Clipping با مقدار $CLIP_NORM = 1.0$ استفاده شد تا از انفجار گرادیان‌ها در شبکه‌های بازگشتی جلوگیری شود.

به‌منظور جلوگیری از بیش‌برازش و انتخاب بهترین وزن‌ها، در هر epoch مقدار `val_loss` با بهترین مقدار قبلی مقایسه شد و در صورت بهبود، مدل به‌عنوان بهترین `checkpoint` ذخیره گردید. در نهایت بهترین مدل در فایل `best_lstm.pt` ذخیره شد.

نتایج نشان می‌دهد که مقدار خطای آموزش از حدود 0.2745 در epoch اول به حدود 0.0477 در epoch دهم کاهش یافته است که بیانگر یادگیری مؤثر مدل از داده‌های آموزشی است. همچنین خطای اعتبارسنجی نیز به‌صورت کلی روند کاهشی داشته و بهترین مقدار آن برابر:

$$\text{best_val} = 0.1660$$

به‌دست آمده است) در epoch هشتم. (پس از این نقطه، مقدار `val_loss` در epoch‌های بعدی اندکی افزایش پیدا کرده است (مثلاً ۰.۱۷۵۳ و ۰.۱۷۳۶)، که می‌تواند نشانه شروع بیش‌برازش خفیف باشد. بنابراین انتخاب `checkpoint` با کمترین `val_loss` باعث می‌شود بهترین تعمیم‌پذیری مدل برای داده‌های آینده حفظ گردد.

۵-۶: ارزیابی مدل LSTM روی اعتبارسنجی (مقیاس واقعی فروش)

پس از بارگذاری بهترین `checkpoint (best_lstm.pt)` و انجام پیش‌بینی روی مجموعه اعتبارسنجی، خروجی‌ها از حالت نرمال شده به مقیاس واقعی فروش بازگردانده شدند (`inverse transform`) و معیارهای خطا محاسبه شد.

- VAL MAE (overall): 1321.27
- VAL RMSE (overall): 1937.95

MAE per step: [1271.57, 1288.65, 1306.81, 1310.91, 1331.64, 1353.45, 1385.87] •
RMSE per step: [1878.45, 1900.44, 1924.02, 1922.51, 1947.04, 1977.33, 2012.41] •

این نتایج نشان می‌دهد با افزایش افق پیش‌بینی، خطا به صورت تدریجی افزایش پیدا می‌کند (اثر دشوارتر شدن پیش‌بینی در روزهای دورتر).

همچنین نمونه‌های چاپ‌شده از مقادیر واقعی و پیش‌بینی‌شده نشان می‌دهد مدل در برخی بازه‌ها اختلاف قابل توجهی دارد، که می‌تواند ناشی از جهش‌های ناگهانی فروش یا رویدادهایی باشد که به طور کامل در ویژگی‌ها منعکس نشده‌اند.

همچنین نمونه‌های چاپ‌شده از مقادیر واقعی و پیش‌بینی‌شده نشان می‌دهد مدل در برخی بازه‌ها اختلاف قابل توجهی دارد، که می‌تواند ناشی از جهش‌های ناگهانی فروش یا رویدادهایی باشد که به طور کامل در ویژگی‌ها منعکس نشده‌اند.